

단일 거래를 넘어서: D-EMAML 향상된 자금세탁방지 탐지를 위한 이중-엣지 모티프 신경망

Beyond Single Transactions: D-EMAML —

Dual-Edge Motif Neural Networks for Enhanced Anti-Money Laundering
Detection

Dongmei Han · Min Min · Yuchen Wang · Guoming Xu · Xiaofeng Zhou

상하이재경대학교 (Shanghai University of Finance and Economics)

제40회 AAAI 인공지능 학회 (AAAI-26)

초록 (Abstract)

자금세탁방지(AML) 탐지는 금융 리스크 관리에서 매우 중요하다. 그래프 신경망(GNN)이 유망한 결과를 보였지만, 기존 모티프(motif) 기반 접근법은 주로 단순 그래프에서의 노드 이상 탐지에 초점을 맞춰 왔으며, 이는 방향성 시간적 거래 네트워크에서 이상 엣지를 직접 식별하는 데 한계가 있다. 또한 **이중-엣지 모티프 (dual-edge motifs)**라 불리는 연속 거래 관계는 기존 AML 연구에서 거의 다뤄지지 않았다. 이러한 공백을 메우기 위해 우리는 **D-EMAML 프레임워크**를 제안한다. 이는 (1) 가지치기(pruning)를 갖춘 GPU 가속 이중-엣지 모티프 그래프 생성기 **Fast-Motif-Gen**, (2) 모티프 유형 간 정보 중복을 줄이는 어텐션 강화 이기종 (heterogeneous) GNN 모듈 **D-EMGNN**, (3) 모티프 그래프의 예측을 원래 그래프로 투영하는 라벨 집계 기법 **MELP**로 구성된다. 실제 데이터와 합성 데이터에 대한 광범위한 실험에서 대표적인 베이스라인 대비 유의미한 성능 향상을 보였고, 각 구성요소의 기여도를 검증했다. 우리가 아는 한, 이중-엣지 모티프 그래프를 GNN 기반 AML 엣지 이상 탐지에 적용한 첫 번째 연구이다.

코드 — <https://github.com/SUFE-Finlab/D-EMAML> | **확장 버전** — <https://paper.fin-lab.ai/paper?id=1>

1. 서론 (Introduction)

금융 거래의 복잡성이 증가하면서 금융 사기의 문제가 심화되고 있으며, 금융기관과 규제기관은 견고한 탐지 방법론을 필요로 한다(Hilal, Gadsden, and Yawney 2022; Pourhabibi et al. 2020). 이에 현대 자금세탁방지(AML) 연구는 그래프 신경망(GNN)(Hamilton, Ying, and Leskovec 2017; Kipf and Welling 2016; Xu et al. 2018)을 적극 활용해 왔으며, 그룹 인식(group-aware) 모델과 모티프 증강(motif-augmented) 모델 같은 고급 변형도 등장했다(Cheng et al. 2023; Motie and Raahemi 2024; Wu et al. 2022; Wang et al. 2023).

복잡 네트워크에서 근본적인 고차 구조를 나타내는 **모티프**(Milo et al. 2002)는 저수준 상호작용을 세탁 순환(laundering cycles) 같은 의미적으로 풍부한 패턴으로 추상화하는 강력한 메커니즘을 제공한다(Wang et al. 2023; Huang et al. 2021; Xiao et al. 2024). 그러나 기존 GNN 기반 접근법에는 심각한 한계가 있다. 이들은 주로 단순 방향 그래프 위의 노드 중심 모티프(예: 3~4개 노드 구조)에 집중하여, 거래 모니터링에서 핵심 과제인 **엣지 수준 이상 탐지**를 충분히 다루지 못한다(Motie and Raahemi 2024). 그림 1에서 보듯, 기존 노드 모티프 방식은 여러 거래를 집계하기 때문에 세밀한 세탁 흐름을 구분하지 못할 뿐 아니라 필수적인 엣지 속성의 손실을 초래한다. 반면 제안하는 엣지-모티프 접근은 개별 거래를 고차 구조로 변환한다.




그림 1 노드 중심 모티프와 제안하는 이중-엣지 모티프의 비교. 이중-엣지 모티프는 방향성 흐름과 엣지 속성을 보존하여 거래 시퀀스를 더 세밀하게 분석할 수 있다. (원문 Figure 1)

이러한 결함들은 MotifGNN(Wang et al. 2023), MADG(Yuan, Shao, and Yan 2023), HOGAT(Huang et al. 2021) 같은 기존 방법의 부적합성을 드러낸다. 이들의 정적이고 노드 중심적인 아키텍처는 자금세탁 수법에 내재한 동적 금융 흐름을 포착하기 어렵다. 이에 우리는 **이중-엣지 모티프** 개념을 도입한다 — 자금의 방향성·시간적 이동을 명시적으로 모델링하는 연속 거래 쌍(sequential pairs of transactions)이다. 이러한 구조는 구조화(structuring), 계층화(layering) 같은 정교한 불법 수법을 표현하는 기초적인 "문법(grammar)" 역할을 한다. 이러한 잠재력에도 불구하고, 강력한 엣지 중심 모티프를 거래 수준 이상 탐지에 적용하는 것은 아직 크게 개척되지 않은 연구 영역으로 남아 있다.

이 간극을 메우기 위해 우리는 엣지 이상을 직접 탐지하는 새로운 프레임워크 **D-EMAML(Dual-Edge Motif Anti-Money Laundering)**을 제안한다. 그림 2에 묘사된 것처럼, 우리의 접근은 가속 알고리즘 **Fast-Motif-Gen**으로 시작해 통계 기반 가지치기 전략으로 이중-엣지 모티프를 효율적으로 생성·선택한다. 이 인스턴스들로 모티프 그래프를 구성하고, 표현 학습을 위해 이기종 편향 MGCN(Motif Graph Convolutional Network) 층과 구조 인식 정보 중복 제거(SAIRR) 모듈을 갖춘 **D-EMGNN**을 제안한다. 마지막으로 **MELP(Motif-to-Edge Label Propagation)**가 학습된 모티프 인스턴스 수준 예측을 원래 거래 엣지로 다시 매핑하여 정확한 이상 탐지를 수행한다.




그림 2 제안하는 D-EMAML 프레임워크의 전체 워크플로 — 모티프 생성 및 그래프 구축에서 표현 학습, 그리고 엣지 수준 이상 탐지를 위한 라벨 전파까지. (원문 Figure 2)

주요 기여는 다음과 같이 요약된다.

- 다중-방향 시간 네트워크 위에서 GNN 기반 엣지 이상 탐지를 위한 이중-엣지 모티프 그래프를 최초로 구성하고, 노드 중심 모티프의 한계를 극복하는 MELP를 포함한 D-EMAML을 도입했다.
- 어텐션 기반 중복 제거 모듈(SAIRR)과 이기종 편향 메커니즘(MGCN)을 통합한 D-EMGNN을 제안하여 모티프 이기종성을 효과적으로 포착했다. 실제·합성 데이터 모두에서 우수한 성능을 달성했고, 절제 연구로 SAIRR과 MGCN의 유효성을 검증했다.
- 가지치기 전략과 제어 샘플링을 갖춘 시간 범위 기반 생성기 Fast-Motif-Gen을 설계하여, 정확도 저하 없이 효율적이고 확장 가능한 모티프 그래프 구축을 가능하게 했다.
- AML 엣지 분석을 단일 거래에서 이벤트 쌍(이중-엣지 모티프)으로 발전시켜, 특징적인 자금세탁 패턴의 인식을 크게 향상시켰다.

2. 관련 연구 (Related Work)

거래 세탁 탐지를 위한 GNN

그래프 신경망(GNN)은 금융 사기 탐지에서 상당한 가능성을 보여 왔다(Motie and Raahemi 2024). 현행 접근법은 집단화된 불법 활동을 식별하기 위한 그래프 증강 기법(Cheng et al. 2023)이나 거래 흐름의 방향 정보를 포착하는 전용 아키텍처(Wu et al. 2022)를 사용한다. 그러나 이러한 방법들은 주로 개별 거래나 단순한 노드 중심 패턴에 집중한다(Cheng et al. 2023; Wu et al. 2022; Li et al. 2023; Huang et

기존 모티프 기반 GNN

이러한 고차 구조를 활용하기 위해 모티프 기반 GNN을 탐구한 연구 흐름이 있다. 그러나 이 방법들은 엣지 수준 AML 탐지의 구체적 요구와 근본적으로 맞지 않는다. 대부분은 노드 수준 태스크(예: 이상 계정 식별)(Wang et al. 2023; Huang et al. 2021; Yuan et al. 2021; Lee et al. 2019) 또는 그래프 수준 분류(Xiao et al. 2024)를 위해 설계되어, 개별 불법 거래를 정확히 짚어내기에는 너무 조악하다. 모티프로부터 초그래프(hypergraph)를 구성하는 방법들(Zhao et al. 2025; Long et al. 2025)도 있으나, 이 과정에서 거래 흐름에 내재한 핵심적인 시간적·다중 관계적 세부 사항이 추상화되어 소실된다. 요컨대, 이들의 정적이고 노드 중심적인 설계는 AML의 동적·방향성·엣지 중심 특성에 부적합하며, 엣지 기반 모티프 이상 탐지에 중대한 공백을 남긴다.

전통적인 노드 중심 모티프(예: 삼각형)와 극명하게 대조되는 엣지 중심 설계는 거래 네트워크 분석에 뚜렷한 장점을 제공한다. 연속 거래 쌍을 명시적으로 모델링하는 이중-엣지 모티프 같은 구조적 프리미티브에 초점을 맞추으로써, 정교한 이상 패턴의 방향성·시간성·다중성(multiplicity) 특성을 자연스럽게 포착한다. 이를 통해 노드 중심 프레임워크가 본질적으로 놓치는 복잡한 행동들을 식별할 수 있다.

3. 문제 정의 (Problem Definition)

3.1 기본 표기

거래 데이터셋을 방향성 시간 그래프(directed temporal graph)(Paranjape, Benson, and Leskovec 2017) $G = (V, E)$ 로 표현한다. V 는 노드 집합이고 $E = \{\varepsilon_i\}_{i=1}^{|E|}$ 는 거래 이벤트 집합이다. 각 이벤트 $\varepsilon_i = (u_i, v_i, t_i, \chi_i, y_i)$ 는 타임스탬프 t_i 에 노드 u_i 에서 노드 v_i 로 향하는 방향성 거래를 나타내며, $\chi_i = (x_{u_i}, x_{v_i}, x_{u_i v_i})$ 는 출발 노드·도착 노드·엣지의 속성 벡터이다. 라벨 $y_i \in \{0, 1\}$ 은 거래가 정상($y_i = 0$)인지 자금세탁 의심($y_i = 1$)인지를 나타낸다. u, v, t, y 를 각각 출발 노드, 도착 노드, 타임스탬프, 거래 라벨의 벡터라 하고, χ 는 정점과 엣지 속성 벡터의 연결이다.

거래는 튜플 (u_i, v_i, t_i) 로 고유하게 식별되며 ε_{uvt} 로 표기한다. 집합 $\varepsilon_{uv} = \{\varepsilon_{ij\tau} \mid i = u, j = v\}$ 는 u 에서 v 로의 모든 이벤트를 포함하고, 마찬가지로 $\varepsilon_{u*} = \{\varepsilon_{ij\tau} \mid i = u\}$ 와 $\varepsilon_{*v} = \{\varepsilon_{ij\tau} \mid j = v\}$ 는 각각 u 에서 출발하는 모든 이벤트와 v 에 도착하는 모든 이벤트를 나타낸다. 이벤트 ε_{uvt} 에 대해 그 n -hop 거래 이웃은 $N_n(\varepsilon_{uvt})$ 로 표기하고, 에이전트 u 의 이웃 집합은 $N(u)$ 로 표기한다.

3.2 거래 이상 탐지

거래 이상 탐지는 기대 행동에서 크게 벗어난 이벤트를 식별하는 것을 목표로 한다. 전체 거래 데이터셋에서 이벤트 배치 집합 E 와 그 유도 이웃 그래프 $G_\varepsilon = \{\bigcup N_n(\varepsilon) \mid \varepsilon \in E\}$ 가 주어졌을 때, 태스크는 실제 라벨 벡터 y 에 근접하게 근사하는 함수 $\hat{y} = \Phi(G)$ 를 학습하는 것이다.

4. 방법론 (Methodology)

제안하는 프레임워크는 세 가지 핵심 구성요소로 이루어진다: (1) 원본 거래 데이터로부터 고수준 모티프 그래프를 효율적으로 구축하는 체계적 접근인 **Fast-Motif-Gen**; (2) 공간 어텐션과 이기종 합성곱으로 구성된 모티프 그래프를 인코딩하도록 설계된 모델 **D-EMGNN**(Dual-Edge Motif Graph Neural Network); (3) 학습된 모티프 표현을 바탕으로 원래 거래의 라벨을 추론하는 모듈 **MELP**(Motif-Edge Label Propagation).

4.1 Fast-Motif-Gen

Fast-Motif-Gen의 핵심 아이디어는 원본 거래 그래프를 고수준 모티프 그래프로 추상화하여, 분석 관점을 개별 거래에서 조율된 세탁 전술로 전환하는 것이다. AML 맥락에서 단일 거래는 우연이 될 수 있지만, 더 큰 패턴의 일부로 보면 그 의미가 증폭된다. 세탁 전술을 새 그래프의 노드로 변환하면 GNN이 그 상호작용을 학습할 수 있다. 예를 들어, 모델은 "fan-in" 패턴 뒤에 "fan-out" 패턴이 자주 이어지는 것이 정교한 세탁 수법의 강력한 지표임을 학습할 수 있다. 이 변환 과정은 정의된 모티프 구조와 결과 모티프 그래프를 보여주는 그림 3에 묘사되어 있다.

이중-엣지 모티프 정의

정의 1 (이중-엣지 모티프 그래프). 모티프 그래프는 무방향 그래프 $M = (\mathcal{M}, \Omega)$ 로 정의된다. 여기서 $\mathcal{M}$ 은 이중-엣지 모티프 인스턴스 집합이고, Ω 는 이들 간의 연결을 나타낸다. 두 모티프 $m_a, m_b \in \mathcal{M}$ 사이에 연결(모티프 엣지)이 존재하는 것은, 그 구성 엣지 집합이 비어있지 않은 교집합을 가질 때, 즉 $E_a \cap E_b \neq \emptyset$ 일 때뿐이다.

정의 2 (이중-엣지 모티프 인스턴스). 각 이중-엣지 모티프(D-EM) 인스턴스 $m_i \in \mathcal{M}$ 는 두 거래의 특정 순차 패턴을 인코딩하는 구조화된 튜플이다.

$$m_i = (V_i, E_i, \delta_i, \omega_i, Y_i, X_i)$$

튜플의 각 원소는 다음과 같이 정의된다.

- $V_i = \{u_i^1, v_i^1, u_i^2, v_i^2\}$: 모티프를 구성하는 정점 집합.
- $E_i = \{\varepsilon_i^1, \varepsilon_i^2\}$ ($t_1 \leq t_2, \varepsilon_1 \cap \varepsilon_2 \neq \emptyset$): 모티프를 구성하는 엣지 쌍.
- $\delta_i = \Delta(t_1, t_2)$: 시간 범위(temporal span) — 모티프의 해당 부분그래프의 지속 시간을 측정하는 스칼라 값.
- ω_i : 모티프의 공간적 클래스. 모든 이진(binary) 모티프의 집합은 $\mathcal{B} = \{b_1, b_2\}$ ($|V_i| = 2$), 모든 삼진(ternary) 모티프의 집합은 $\mathcal{T} = \{t_1, t_2, t_3, t_4\}$ ($|V_i| = 3$)로 표기한다.
- $Y_i = y_1 + 2y_2 \in \{0, 1, 2, 3\}$: 모티프 인스턴스에 연결된 이진 인코딩 라벨 벡터.

- $X_i = \text{concat}(x_{V_i}, x_{V_i}, x_{E_i}, x_{E_i})$: 모티프 인스턴스의 특성 벡터. 모티프의 정점 V_i 와 엣지 E_i 에서 파생된 1차 특성과 집계 특성의 연결로 형성된다.

본 논문에서는 시간 범위 함수로 $\Delta(\cdot) = \lfloor \log_2(t_2 - t_1) \rfloor$ 을 채택한다.




그림 3 모티프 기반 그래프 구축 개요. (a) 이중-엣지 모티프 구조의 예시 — 점선은 특성 공학에 사용되는 관계를 나타낸다. (b) 원본 그래프 G 에서 모티프 그래프 M 으로의 변환 — 모티프 인스턴스(사각형)가 노드가 되고, G 에서 공유된 엣지가 이들 사이에 링크 Ω 를 만든다. (원문 Figure 3)

효율적 모티프 인스턴스 생성

원본 그래프 G 에서 모티프 집합 $\mathcal{M} = \Gamma(G)$ 을 생성하는 것은 계산 비용이 클 수 있다. 알고리즘 1에 나타난 단순 접근법은 중첩 루프로 모든 엣지 쌍의 공유 노드를 검사하여, 대규모 그래프에서 $O(|E|^2)$ 의 감당하기 어려운 시간 복잡도를 갖는다.

Algorithm 2: $A = \text{AdjInd}(e)$: GPU-based Edge Adjacency Indexing

Input: Edge tensor $e \in \mathbb{R}^{2 \times |e|}$ **Output:** $A \in \{0, 1\}^{2 \times 2 \times |e| \times |e|}$

- 1: Let I be the identity matrix of size $|e| \times |e|$
 - 2: $B \leftarrow$ Unsqueeze and repeat e to shape $2 \times |e| \times |e|$
 - 3: $C \leftarrow$ Unsqueeze and repeat e (transposed) to shape $2 \times |e| \times |e|$
 - 4: $A_{0,0} \leftarrow (B_0 = C_0) \wedge (\neg I)$ {Source-Source connection}
 - 5: $A_{1,0} \leftarrow (B_1 = C_0) \wedge (\neg I)$ {Target-Source connection}
 - 6: $A_{0,1} \leftarrow (B_0 = C_1) \wedge (\neg I)$ {Source-Target connection}
 - 7: $A_{1,1} \leftarrow (B_1 = C_1) \wedge (\neg I)$ {Target-Target connection}
 - 8: **return** A
-

알고리즘 2 $A = \text{AdjInd}(e)$: GPU 기반 엣지 인접 인덱싱. 출발-출발, 도착-출발, 출발-도착, 도착-도착 네 가지 연결 유형을 단일 텐서 연산으로 계산한다. (원문 Algorithm 2)

확장성을 위한 모티프 가지치기

제약 없는 모티프 생성은 인접 텐서 A 와 최종 모티프 집합 $\mathcal{M}$ 모두에 감당하기 어려운 메모리 사용을 초래할 수 있다. 확장성을 보장하기 위해 이중 가지치기 전략을 도입한다. 첫째, 도메인 지식이나 데이터 통계에 기반하여 모티프를 시간 범위 δ_i 로 필터링하고, 의미 있는 범위 $[\xi, \eta]$ 내의 것만 유지한다 (그림 4 참조).

$$\mathcal{M}^* = \{m_i \in \mathcal{M} \mid \xi \leq \delta_i \leq \eta\}$$

$$|\mathcal{M}| = \sum_{i=1}^{|V|} \binom{d_i}{2} = \frac{1}{2} \left(\sum_{i=1}^{|V|} d_i^2 \right) - |E|$$

제약 $\sum_{i=1}^{|V|} d_i = 2|E|$ 하에서 옌센 부등식(Jensen's inequality)은 $\sum d_i^2$ 이 차수가 집중될 때 최대화됨을 의미하며, 이는 $|\mathcal{M}|$ 의 상한으로 이어진다.

$$|\mathcal{M}|_{\max} \approx \left\lfloor \frac{2|E|}{d_{\max}} \right\rfloor \binom{d_{\max}}{2} \leq |E|(d_{\max} - 1)$$

이 결과는 최대 차수 $d_{\max}$ 를 제한하는 것이 $\mathcal{M}$ 의 크기를 제어하는 매우 효과적인 전략임을 확인시켜 주며, 전체 과정의 확장성을 보장한다.

4.2 이중-엣지 모티프 그래프 신경망 (D-EMGNN)

제안하는 D-EMGNN 모델은 두 핵심 모듈 — 공간 어텐티브 정보 중복 제거(SAIRR) 모듈과 모티프 그래프 합성곱 네트워크(MGCN) — 를 사용해 모티프 그래프를 처리한다. 과정은 모티프 특성의 선형 변환으로 초기 노드 임베딩을 얻는 것으로 시작한다: $h_i^{(0)} = W_{in}X_i + b_{in}$.

공간 어텐티브 정보 중복 제거 (SAIRR)

AML 맥락에서 서로 다른 모티프 유형(예: 이진 '통과(pass-through)' vs 삼진 'fan-in')이 동일한 금융 계정을 포함할 수 있어 정보 중복이 발생한다. SAIRR은 각 모티프 유형의 고유한 구조 신호를 정제하도록 설계되었다. 먼저 l 층의 은닉 표현 $h^{(l)}$ 을 유형별 공간으로 매핑한다.

$$h_{\omega,i}^{(l)} = W_{\omega}^{(l)} h_i^{(l)} + b_{\omega}^{(l)}, \quad \omega \in \{\mathcal{B}, \mathcal{T}\}$$

그 다음, 중복을 최소화하기 위해 이기종 공간들 사이에서 어텐션 계수를 계산하여 각 모티프 유형의 증분 기여를 동적으로 가중한다.

$$Q_{\omega_i,i}^{(l)} = h_{\omega_i,i}^{(l)} W_{att,\omega_i}^{(l)}$$

$$K_{\omega}^{(l)} = h_{\omega,i}^{(l)} W_{att,\omega}^{(l)}, \quad \omega \neq \omega_i$$

$$\alpha_{\omega} = \frac{\exp \left(\frac{Q_{\omega_i,i}^{(l)} K_{\omega}^{(l)\top}}{\sqrt{|\mathcal{T}| + |\mathcal{B}|}} \right)}{\sum_{\omega' \neq \omega_i} \exp \left(\frac{Q_{\omega_i,i}^{(l)} K_{\omega'}^{(l)\top}}{\sqrt{|\mathcal{T}| + |\mathcal{B}|}} \right)}$$

중복이 억제된 표현 $\tilde{h}^{(l)}$ 은 다음과 같이 계산된다.

$$\tilde{h}_i^{(l)} = \sigma \left(\beta_i^{(l)} \left(h_{\omega_i,i}^{(l)} - \sum_{\omega \neq \omega_i} \alpha_{\omega} h_{\omega,i}^{(l)} \right) \right)$$

$$\beta_i^{(l)} = \sigma \left(h_{\omega_i, i}^{(l)\top} \sum_{\omega \neq \omega_i} \alpha_{\omega} h_{\omega, i}^{(l)} \right)$$

여기서 (9)에 정의된 게이팅 스칼라 $\beta^{(l)}$ 은 모티프 자신의 유형별 임베딩과 다른 유형들의 집계 임베딩 간 유사도를 측정한다. 가중된 중복 정보를 적응적으로 차감함으로써, SAIRR은 모델이 각 세타 전술의 뚜렷한 위상적 역할에 집중하도록 강제한다. 이 접근은 단순 선형 차감 대신 어텐션 기반의 더 세밀한 축소 메커니즘을 사용한다는 점에서 모티프 기반 방법의 기존 연구(Chen et al. 2023)를 개선한다. 워크플로는 그림 5에 묘사되어 있다.




그림 5 공간 어텐티브 정보 중복 제거(SAIRR) 모듈의 워크플로. SAIRR은 어텐션 메커니즘을 사용해 서로 다른 모티프 유형의 중복 정보를 식별하고 차감함으로써 모티프 표현을 정제한다. (원문 Figure 5)

모티프 그래프 합성곱 네트워크 (MGCN)

제안하는 MGCN 층은 이웃 모티프로부터 정보를 집계하며, 표준 그래프 합성곱 네트워크(GCN)(Kipf and Welling 2016)를 이기종 모티프 상호작용을 처리하도록 확장한다. 정교한 AML 수법에서 두 'fan-in' 모티프 간 상호작용은 'fan-in'과 'cycle' 모티프 간 상호작용과는 다른 행동을 의미할 수 있다. 이러한 세타 전술의 "문법"을 포착하기 위해 MGCN은 학습 가능한 유형 인식 편향을 도입한다.

$$h_i^{(l+1)} = \sigma \left(\sum_{j \in \mathcal{N}(m_i) \cup \{m_i\}} \frac{W_p \tilde{h}_j^{(l)}}{\sqrt{d_i d_j}} + b_{\omega_i \omega_j} \right), \quad l < L$$

$$d_i = |\mathcal{N}(m_i)| + 1$$

4.3 모티프-엣지 라벨 전파 (MELP)

그림 6에서 보듯, MELP는 그래프 구조에 내장된 모티프 수준 정보를 활용해 엣지 라벨을 예측하는 새로운 프레임워크를 도입한다. 이 접근에서 모티프 표현은 다층 퍼셉트론(MLP)을 통해 $|Y|$ 차원 공간으로 투영되고, 소프트맥스 함수로 모티프 라벨 확률을 얻는다.

$$P_i^{edge} = \text{MLP}(h_i^{(L)})$$

$$p_{ij}^{edge} = \frac{\exp(P_{ij}^{edge})}{\sum_{k=0}^{2|E|-1} \exp(P_{ik}^{edge})}$$

여기서 p_{ij}^{edge} 는 모티프 i 가 클래스 j 에 할당될 확률을 나타낸다.

엣지 라벨 추론. 모티프 내 각 엣지의 라벨 확률은 모티프 클래스 확률을 주변화(marginalizing)하여 추론한다. 이중-엣지 모티프의 경우 다음과 같이 계산된다.

$$P(y_{i_1} = 1) = p_{i1} + p_{i3}$$

$$P(y_{i_2} = 1) = p_{i2} + p_{i3}$$

원본 그래프의 엣지 ε_k 에 대한 최종 예측 라벨 확률 $\hat{y}_{\varepsilon_k}$ 는 그것을 포함하는 모든 모티프의 추론 확률을 평균하여 계산한다.

$$\hat{y}_{\varepsilon_k} = P(y_{\varepsilon_k} = 1) = \frac{\sum_{m_i \in \mathcal{M}, \varepsilon_k = \varepsilon_{i_1}} P(y_{i_1} = 1)}{|\{m_i : \varepsilon_k \in m_i\}|} + \frac{\sum_{m_i \in \mathcal{M}, \varepsilon_k = \varepsilon_{i_2}} P(y_{i_2} = 1)}{|\{m_i : \varepsilon_k \in m_i\}|}$$

모델은 원본 그래프의 모든 엣지에 대한 이진 교차 엔트로피 손실을 최소화하여 학습된다.

$$L(y, \hat{y}) = -\frac{1}{|E|} \sum_{i=1}^{|E|} y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)$$

5. 실험 (Experiments)

5.1 데이터셋

실제 AML 데이터셋은 엄격한 프라이버시와 규제 제약으로 인해 극히 드물다. 따라서 우리의 평가는 독점적인 실세계 은행 데이터셋과 복잡한 금융 거래를 모사하여 중요한 대용(proxy) 역할을 하는 두 개의 대규모 공개 벤치마크를 전략적으로 결합한다.

- **TransBank**: 익명 은행의 독점 거래 데이터셋으로, 이상 행동이 포함된 선별된 레코드 부분집합을 포함한다. 엄격한 규제 준수에 따라 모든 개인식별정보(PII)가 제거되었고 데이터는 실험 후 안전하게 파기되었다.
- **AMLWorld**: AMLWorld 시뮬레이터(Altman et al. 2023)의 대규모 합성 벤치마크로, AML 연구를 위한 은행 간 거래 흐름을 현실적으로 모델링하도록 설계되었다.
- **DgraphE**: (Huang et al. 2022)가 도입한 실제 거래 데이터셋이다. 원래의 노드 분류 태스크를 엣지 중심 탐지(이상 거래 식별)로 재활용하여 DgraphE라 명명한 버전을 만들었다.

표 1 실험에 사용된 데이터셋의 통계. (원문 Table 1)

데이터셋	$ V $	$ E $	$\dim_{x_u}$	$\dim_{x_{uv}}$	이상 비율(%)
TransBank	130M	4.5B	17	289	0.02
AMLWorld	0.51M	5.07M	-	47	0.15
DgraphE	3.7M	4.3M	17	-	14.5

5.2 실험 설정

환경. 실험은 Ubuntu 24.04 LTS 서버(AMD 9654 CPU 2기, NVIDIA Tesla H800(80GB) GPU 2기, RAM 1.5TB) 또는 Ubuntu 24.04 LTS 서버(Intel Xeon Gold 6430 CPU 2기, NVIDIA RTX 4090 GPU 8기, RAM 512GB)에서 자원 가용성에 따라 수행되었다. 모든 구현은 torch-geometric Python 패키지(Fey and Lenssen 2019)에 기반한다. 은행 규정 및 비밀유지 계약으로 인해 TransBank 데이터셋과 일부 해당 실험 세부사항은 공개할 수 없다.

베이스라인. 제안하는 이중-엣지 모티프 그래프의 효과를 종합적으로 평가하기 위해 비교 분석을 수행한다. 평가의 핵심은 원본 그래프 위의 대표적인 GNN 아키텍처와 모티프 기반 그래프 위의 대응 모델의 성능을 비교하는 것이다. 두 설정을 구별하기 위해 원본 그래프에서 동작하는 모델에는 "e" 접미사(예: GINe), 이중-엣지 모티프 그래프에서 동작하는 모델에는 "m" 접미사(예: GINm)를 붙인다. 기본 베이스라인으로는 학습 가능한 엣지 속성을 지원하는 널리 인정받는 GNN 아키텍처 GIN(Xu et al. 2018), GAT(Velićković et al. 2017), PNA(Corso et al. 2020)를 포함한다. 특히 PNA의 아키텍처는 이중-엣지 모티프 그래프에 잘 정의되지 않거나 직접 적용할 수 없는 사전 계산 그래프 통계(예: 차수 분포)에 의존하므로, 모티프 그래프 비교에서는 PNAm을 적응된 GCN(Kipf and Welling 2016) 모델(GCNm)로 대체했다. 또한 고차 구조 관련 최신 방법과의 벤치마크를 위해 공식 코드 가용성으로 인해 HOGAT(Huang et

al. 2021)과 GUIDE(Yuan et al. 2021)를 포함하고, 우리의 엣지 수준 예측 태스크와 방법론에 맞게 신중하게 적응시켜 각각 HOGATm, GUIDEm으로 지칭한다. 중요하게도, 우리의 실험 모델은 종단간(end-to-end) 특성을 갖는다. 따라서 우리의 실험 결과는 전체 데이터셋에서 특성(예: ego-id)을 미리 계산하고 증강하는 방법들 — 우리는 이를 덜 현실적이라 본다 — 의 결과와는 다르다.

평가 지표. 평가 지표로 F1-score와 Precision-Recall 곡선 아래 면적(AUPRC)을 사용하며, 이는 AML 태스크에 내재한 심각한 클래스 불균형을 처리하기 위해 특별히 선택되었다. F1-score는 단일 결정 임계값에서 정밀도와 재현율의 균형 잡힌 측정을 제공한다. 반면 AUPRC는 모든 임계값에 걸쳐 성능을 평가함으로써 더 포괄적이고 견고한 평가를 제공하며, 드문 양성 인스턴스를 식별하는 모델의 능력을 더 잘 반영하므로 중요하다. 따라서 AUPRC를 주 평가 기준으로 삼는다.

학습 상세. 먼저 데이터를 시간 순으로 학습·검증·테스트 세트로 분할한다. 모든 모델은 서브샘플링 전략과 함께 최대 50 에폭까지 학습되었다. 검증 세트에서 최고 F1-score를 달성한 모델 체크포인트를 저장하고, 이 모델을 테스트 세트에서 한 번 평가하여 최종 성능을 보고했다. 공정한 비교를 위해 모든 모델은 동일한 입력 특성과 256차원 은닉층을 갖는 2층 GNN 아키텍처를 공유했다. hop당 최대 100개의 이웃을 샘플링하는 2-hop 이웃 샘플링 전략을 사용했다. 학습률은 $\{10^{-5}, 5 \times 10^{-4}, 10^{-4}\}$ 에서, 배치 크기는 $\{16, 32, 64, 128\}$ 에서 조정했다.

5.3 성능

실험 결과는 5회 독립 실행의 평균 $\pm$ 표준편차로 보고된다. 각 항목은 이 형식으로 제시된다.

표 2 데이터셋별 성능 비교 및 절제 연구 결과. 테스트 세트 최고 성능은 볼드체. (원문 Table 2)

모델	TransBank		AMLWorld		DgraphE	
	F1(%)	AUPRC(%)	F1(%)	AUPRC(%)	F1(%)	AUPRC(%)
GINe	7.84 $\pm$ 0.52	4.69 $\pm$ 0.95	10.8 $\pm$ 0.81	7.69 $\pm$ 0.91	25.3 $\pm$ 1.06	48.4 $\pm$ 0.08
GATe	12.3 $\pm$ 1.56	6.42 $\pm$ 0.85	16.8 $\pm$ 2.68	8.78 $\pm$ 0.58	20.7 $\pm$ 0.87	48.5 $\pm$ 0.25
PNAe	13.9 $\pm$ 1.47	7.87 $\pm$ 1.24	19.4 $\pm$ 2.44	11.8 $\pm$ 1.89	21.2 $\pm$ 1.45	46.4 $\pm$ 0.01
GINm	14.5 $\pm$ 1.22	5.84 $\pm$ 1.67	16.2 $\pm$ 1.68	7.58 $\pm$ 1.94	32.4 $\pm$ 1.84	53.8 $\pm$ 0.16
GATm	16.8 $\pm$ 1.97	9.47 $\pm$ 1.59	24.4 $\pm$ 0.91	12.9 $\pm$ 1.18	33.2 $\pm$ 1.57	54.1 $\pm$ 0.21
GCNm	17.4 $\pm$ 1.58	10.2 $\pm$ 1.48	23.1 $\pm$ 1.13	11.9 $\pm$ 0.77	33.1 $\pm$ 1.33	52.7 $\pm$ 0.37
HOGATm	4.37 $\pm$ 0.32	2.62 $\pm$ 0.39	10.7 $\pm$ 2.15	7.23 $\pm$ 0.89	23.2 $\pm$ 1.38	47.7 $\pm$ 0.02
GUIDEm	7.62 $\pm$ 0.72	3.02 $\pm$ 0.39	12.4 $\pm$ 1.73	8.64 $\pm$ 0.76	19.6 $\pm$ 1.18	46.3 $\pm$ 0.17
D-EMGNN	18.6$\pm$1.24	14.2$\pm$1.77	26.4$\pm$1.55	15.2$\pm$1.96	35.6$\pm$1.85	56.2$\pm$0.03
w/o SAIRR	15.4 $\pm$ 1.06	8.79 $\pm$ 0.87	21.2 $\pm$ 0.44	10.8 $\pm$ 0.71	31.9 $\pm$ 1.29	54.3 $\pm$ 0.24
w/o MGCN	11.2 $\pm$ 1.26	6.24 $\pm$ 0.47	16.8 $\pm$ 1.87	7.36 $\pm$ 1.05	24.9 $\pm$ 1.67	47.5 $\pm$ 0.08
w/o both	12.7 $\pm$ 1.15	7.48 $\pm$ 0.58	18.0 $\pm$ 1.09	8.39 $\pm$ 0.91	28.3 $\pm$ 1.73	51.7 $\pm$ 0.12

모델 비교. 모든 모델의 성능은 표 2에 상술되어 있다. 결과는 세 가지 핵심 사항을 강조한다. 1) **모티프 표현의 가치:** 표의 첫 두 블록 간 직접 비교(예: GINe 대 GINm)는 이중-엣지 모티프 그래프로 전환하는 것만으로도 모든 GNN 백본에서 상당한 성능 향상을 가져옴을 보여준다. 이는 고차 구조 인코딩의 이점을 확인시켜 준다. 2) **D-EMGNN의 우월성:** 우리의 D-EMGNN 모델은 세 데이터셋 모두에서 다른 모든 모델을 일관되게 능가한다. 불균형 데이터에 필수적인 AUPRC 지표에서 그 우위가 특히 두드러진다. 3) **고차 방법과의 비교:** D-EMGNN의 성능은 엣지 탐지 태스크에서 저조한 성능을 보인 HOGATm, GUIDEm 같은 다른 고차 방법들과 극명하게 대비된다. 이는 이중-엣지 모티프 그래프 위에서 제안된 메시지 패싱 방식의 효과성과 견고성을 강조한다.

절제 연구. 표 2의 마지막 블록은 데이터셋에서의 모듈 절제 실험 결과를 보고한다. 완전한 D-EMGNN 모델은 모든 데이터셋에서 일관되게 최고 성능을 달성한다. SAIRR 또는 MGCN의 $b_{\omega_i\omega_j}$ 항 중 하나를 제거하면 F1과 AUPRC 모두에서 눈에 띄는 하락이 발생하여 각 구성요소의 필수적인 역할을 강조한다. 나아가 두 모듈을 동시에 제거하면 SAIRR만 제거한 경우보다 상당한 추가 성능 하락을 일으켜, 두 모듈이 전체 모델 효과에 중요함을 보여준다. 흥미롭게도, 두 모듈을 모두 제거하면 모델이 동종(homogeneous) 변형으로 퇴화하는데, 이는 $b_{\omega_i\omega_j}$ 항만 절제한 변형보다 나은 성능을 보인다. 이는 동종 메시지 패싱 메커니즘으로 이기종 임베딩 표현을 학습하는 것이 오히려 모델 성능에 해로울 수 있음을 시사한다.

하이퍼파라미터 분석. AMLWorld 데이터셋에서 ξ 를 0으로 고정하고 다양한 η 값에 대한 D-EMAML 모델의 성능을 표 3에 나타낸다. η 가 증가함에 따라 F1-score와 AUPRC가 처음에는 향상되어 $\eta = 6$ 에서 최적 결과에 도달하고, 그 이후에는 성능이 정체된다. 동시에 에폭당 학습 시간이 증가하고 실행 가능한 최대 배치 크기는 감소한다. 나아가 $\eta = 5$ 에서의 성능은 $\eta = 6$ 과 유의미하게 다르지 않음을 관찰했다. 이러한 결과는 제안된 가지치기 전략이 모델이 중요한 모티프 인스턴스에 집중하게 하고, 학습 세트의 확장을 가능하게 하며, 학습 시간 오버헤드를 줄임을 보여준다.

표 3 다양한 η 값($\xi = 0$)에서 AMLWorld에 대한 D-EMAML의 성능. 테스트 세트 최고 성능은 볼드체. (원문 Table 3)

η	3	4	5	6
F1(%)	7.89±0.45	21.5±0.80	24.7±0.90	26.4±1.55
AUPRC(%)	2.00±0.31	10.3±1.44	13.5±0.98	15.2±1.96
실행 시간(분)	15	30	65	75
최대 배치 크기	128	64	32	16

6. 결론 (Conclusion)

우리는 금융 도메인 지식을 고차 그래프 표현에 직접 내장함으로써 엣지 수준 이상 탐지를 근본적으로 발전시키는 자금세탁방지 프레임워크 **D-EMAML**을 소개한다. 우리의 이중-엣지 모티프 그래프는 자금세탁 패턴을 기초 구성 요소로 모델링하여 이를 구체화하고, 전통적 방법이 실패하는 구조 분석과 직접적인 엣지 수준 예측 사이의 중대한 간극을 메운다. 맞춤형 SAIRR과 MGCN 모듈로 구동되는 D-EMAML의 모티프 인식 표현은 GNN이 원본 그래프 위의 대응 모델 대비 상당한 성능 도약을 달성하게 하며, 대규모 데이터

셋에서 검증되었다. 우리의 효율적인 가지치기 전략은 이러한 정교한 분석이 실제 배포에 적합함을 보장한다. 궁극적으로 D-EMAML은 도메인 전문성을 그래프 학습 모델의 구조와 융합하는 새로운 패러다임을 확립하여, 중요한 응용 분야의 향후 연구를 위한 견고한 기반을 제공한다. 이 접근은 금융 보안을 위한 강력한 모델을 제공할 뿐 아니라 다른 고위험 분야에서 더 해석 가능하고 도메인 인식적인 AI 시스템을 개발하는 길을 제시한다. 프레임워크의 주요 한계는 고립된 세탁 거래에 대한 민감도가 낮다는 점이다. 향후 연구는 메모리 최적화를 통한 알고리즘 확장성 강화와 모델 해석가능성 개선에 우선순위를 둘 것이다.

감사의 글 (Acknowledgments)

모든 저자가 이 연구에 동등하게 기여했다. Xiaofeng Zhou가 교신저자이다. 이 연구는 중국 국가자연과학기금(National Natural Science Foundation of China) 핵심 특별 기금(과제번호 72342034 & 72342021)의 지원을 받았다. 또한 중국 교육부(MOE) 철학사회과학 혁신팀(금융기술 및 보안 거버넌스)의 지원도 받았다.

참고문헌 (References)

1. Altman, E.; Blanusă, J.; Von Niederhäusern, L.; Egressy, B.; Anghel, A.; and Atasu, K. 2023. Realistic synthetic financial transactions for anti-money laundering models. *Advances in Neural Information Processing Systems*, 36: 29851–29874.
2. Chen, X.; Cai, R.; Fang, Y.; Wu, M.; Li, Z.; and Hao, Z. 2023. Motif graph neural network. *IEEE Transactions on Neural Networks and Learning Systems*.
3. Cheng, D.; Ye, Y.; Xiang, S.; Ma, Z.; Zhang, Y.; and Jiang, C. 2023. Anti-money laundering by group-aware deep graph learning. *IEEE Transactions on Knowledge and Data Engineering*, 35(12): 12444–12457.
4. Corso, G.; Cavalleri, L.; Beaini, D.; Liò, P.; and Velicković, P. 2020. Principal neighbourhood aggregation for graph nets. *Advances in Neural Information Processing Systems*, 33: 13260–13271.
5. Egressy, B.; Von Niederhäusern, L.; Blanusă, J.; Altman, E.; Wattenhofer, R.; and Atasu, K. 2024. Provably powerful graph neural networks for directed multigraphs. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(10), 11838–11846.
6. Fey, M.; and Lenssen, J. E. 2019. Fast graph representation learning with PyTorch Geometric. *arXiv preprint arXiv:1903.02428*.
7. Hamilton, W.; Ying, Z.; and Leskovec, J. 2017. Inductive representation learning on large graphs. *Advances in Neural Information Processing Systems*, 30.
8. Hilal, W.; Gadsden, S. A.; and Yawney, J. 2022. Financial fraud: a review of anomaly detection techniques and recent advances. *Expert Systems with Applications*, 193: 116429.
9. Huang, L.; Zhu, Y.; Gao, Y.; Liu, T.; Chang, C.; Liu, C.; Tang, Y.; and Wang, C.-D. 2021. Hybrid-order anomaly detection on attributed networks. *IEEE Transactions on Knowledge and Data Engineering*, 35(12): 12249–12263.

10. Huang, X.; Yang, Y.; Wang, Y.; Wang, C.; Zhang, Z.; Xu, J.; Chen, L.; and Vazirgiannis, M. 2022. Dgraph: A large-scale financial dataset for graph anomaly detection. *Advances in Neural Information Processing Systems*, 35: 22765–22777.
11. Huang, Z.; Huang, Y.; Qian, P.; Chen, J.; and He, Q. 2023. Demystifying bitcoin address behavior via graph neural networks. In *2023 IEEE 39th International Conference on Data Engineering (ICDE)*, 1747–1760.
12. Kipf, T. N.; and Welling, M. 2016. Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907*.
13. Lee, J. B.; Rossi, R. A.; Kong, X.; Kim, S.; Koh, E.; and Rao, A. 2019. Graph convolutional networks with motif-based attention. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management*, 499–508.
14. Li, X.; Li, Y.; Mo, X.; Xiao, H.; Shen, Y.; and Chen, L. 2023. Diga: Guided diffusion model for graph recovery in anti-money laundering. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 4404–4413.
15. Lin, D.; Wu, J.; Huang, T.; Lin, K.; and Zheng, Z. 2023. Who is who on Ethereum? Account labeling using heterophilic graph convolutional network. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 54(3): 1541–1553.
16. Long, J.; Ji, S.; Wang, Z.; Chen, T.; and Yang, L. 2025. A hypergraph neural network with motif interaction enhancement. In *Pacific-Asia Conference on Knowledge Discovery and Data Mining*, 383–394. Springer.
17. Luo, X.; Han, X.; Zuo, W.; Wu, X.; and Liu, W. 2024. MLaD2: A semi-supervised money laundering detection framework based on decoupling training. *IEEE Transactions on Information Forensics and Security*, 19: 4518–4533.
18. Milo, R.; Shen-Orr, S.; Itzkovitz, S.; Kashtan, N.; Chklovskii, D.; and Alon, U. 2002. Network motifs: simple building blocks of complex networks. *Science*, 298(5594): 824–827.
19. Motie, S.; and Raahemi, B. 2024. Financial fraud detection using graph neural networks: A systematic review. *Expert Systems with Applications*, 240: 122156.
20. Paranjape, A.; Benson, A. R.; and Leskovec, J. 2017. Motifs in temporal networks. In *Proceedings of the Tenth ACM International Conference on Web Search and Data Mining*, 601–610.
21. Pourhabibi, T.; Ong, K.-L.; Kam, B. H.; and Boo, Y. L. 2020. Fraud detection: A systematic literature review of graph-based anomaly detection approaches. *Decision Support Systems*, 133: 113303.
22. Velickovic, P.; Cucurull, G.; Casanova, A.; Romero, A.; Liò, P.; and Bengio, Y. 2017. Graph attention networks. *arXiv preprint arXiv:1710.10903*.
23. Wang, D.; Zhang, Z.; Zhao, Y.; Huang, K.; Kang, Y.; and Zhou, J. 2023. Financial default prediction via motif-preserving graph neural network with curriculum learning. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2233–2242.
24. Wu, R.; Ma, B.; Jin, H.; Zhao, W.; Wang, W.; and Zhang, T. 2022. Grande: a neural model over directed multigraphs with application to anti-money laundering. In *2022 IEEE International Conference on Data Mining (ICDM)*, 558–567. IEEE.
25. Xiao, C.; Pang, S.; Tai, W.; Huang, Y.; Trajcevski, G.; and Zhou, F. 2024. Motif-consistent counterfactuals with adversarial refinement for graph-level anomaly detection. In *Proceedings*

- of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 3518–3526.
26. Xu, K.; Hu, W.; Leskovec, J.; and Jegelka, S. 2018. How powerful are graph neural networks? *arXiv preprint arXiv:1810.00826*.
27. Yuan, X.; Zhou, N.; Yu, S.; Huang, H.; Chen, Z.; and Xia, F. 2021. Higher-order structure based anomaly detection on attributed networks. In *2021 IEEE International Conference on Big Data (Big Data)*, 2691–2700. IEEE.
28. Yuan, Z.; Shao, M.; and Yan, Q. 2023. Motif-level anomaly detection in dynamic graphs. *IEEE Transactions on Information Forensics and Security*, 18: 2870–2882.
29. Zhao, J.-L.; Zhang, X.-J.; Ding, X.; Zhang, X.; and Zhang, H.-F. 2025. Enhancing graph structure learning via motif-driven hypergraph construction. *IEEE Transactions on Network Science and Engineering*.

번역 참고: 본 문서는 AAAI-26에 게재된 원 논문의 한국어 번역본으로, 전문 용어는 한국어와 영어 원문을 병기했다. 그림과 알고리즘은 원문 PDF에서 발췌한 이미지이며, 표와 수식은 한국어로 재구성했다. 참고문헌은 원문과 동일하게 영문으로 유지했다.