

AML 탐지 모델 v7 — 파이프라인과 모델은 이렇게 만들었습니다

프론트엔드·백엔드·인프라 팀원이 서비스 연동을 준비할 수 있도록, v7 시스템을 "무엇이 들어가서 무엇이 나오는가" 관점으로 설명하는 보고서입니다. ML 사전 지식 없이 읽을 수 있게 썼습니다.

대상 시스템 `AML_GNN_edge_classification_7_research_gradeeeee.ipynb` 작성 AI 파트 작성일 2026-08-10

독자 FE · BE · 인프라 · 기획 관련 문서 노트북 7종 종합 설명서 / v7 심층 설명서 (개발자용)

목차

- 0 이 모델은 무엇을 하는 물건입니까

1 파이프라인 구축 — 8단계 데이터 흐름

2 모델 구축 — 컴포넌트 관점으로

3 산출물(아티팩트) 명세 — 서버에 필요한 파일들

4 운영(서빙) 흐름은 이렇게 됩니다

5 팀별 연동 포인트 — FE / BE / 인프라

6 미결정 사항과 필요한 결정

7 출처

0. 이 모델은 무엇을 하는 물건입니까

한 문장으로: 거래 1건이 들어오면, 그 거래와 관련된 과거 거래 이력을 그래프로 보고 "자금세탁 위험도"를 0~1 확률로 출력하는 분류기입니다. 계좌를 점, 거래를 화살표로 보는 그래프 신경망(GNN)이라서, 개별 거래의 금액·통화뿐 아니라 "이 계좌가 최근 1시간에 몇 명에게 나눠 보냈는가" 같은 **관계 패턴**까지 판단에 사용합니다.

입력	판정 대상 거래(들) + 직전 과거 거래 최대 10만 건(컨텍스트)
출력	거래별 위험도 확률(보정됨) + 경보 여부 플래그 + (보조) 계좌별 위험도
판정 단위	거래 1건 (분 단위 배치로 묶어 처리하는 운영 형태를 가정)
학습 데이터	IBM AMLworld HI-Small 합성 거래 5,078,336건 (양성 0.1019%)
서비스 내 위치	알림/케이스 큐에 올라갈 의심 거래를 만들어내는 탐지 엔진 . 케이스 상세 화면의 "AI 모델 스코어"와 "판단 근거"가 이 모델의 출력입니다

v7이 이전 버전(v6)과 다른 핵심 한 가지

v7은 성능 숫자를 올린 버전이 아니라, "**운영에서 재현되지 않는 점수 부풀림(누수)**"을 제거하고 **확률·임계값·모니터링을 운영 가능하게 만든 버전**입니다. 판정 시점에 실제로 알 수 있는 정보(과거)만 쓰도록 그래프 구성부터 강제했기 때문에, 여기서 나오는 성능 수치가 곧 서비스에서 기대할 수 있는 수치에 가장 가깝습니다. 단, 본학습 실행은 아직 완주 전입니다(\$6).

1. 파이프라인 구축 — 8단계 데이터 흐름

학습 파이프라인은 노트북 안에서 8개 스테이지로 구성됩니다. 각 스테이지는 함수 단위로 분리되어 있어, 추후 배치 잡이나 학습 서비스로 옮길 때 이 단위 그대로 이식하면 됩니다.

1 적재·표준화 (locate_dataset → _canonicalize)

원천 파일을 자동 탐색(전처리 산출물 parquet 우선 → CSV → zip)하고, 어떤 소스든 **필수 9컬럼의 표준 스키마**로 변환합니다. 계좌 키 합성(은행|계좌번호), 중복 제거, 시간순 안정 정렬, 계좌 정수 ID 부여, 경과 분(minute) 계산까지 여기서 끝냅니다. 필수 컬럼이 없으면 즉시 실패시킵니다 — **실데이터 연동 시 BE가 맞춰줘야 할 인터페이스가 바로 이 9컬럼**입니다(\$5).

입력: CSV/parquet/zip → 출력: 표준 DataFrame (5,078,336행)

2 시간순 4분할 (chronological_splits)

train 55% / val 15% / calib 15% / test 15%로 시간순으로 자릅니다. 무작위 분할이 아닌 이유는 "과거로 학습해 미래를 맞히는" 운영 상황을 그대로 재현하기 위해서입니다. calib(보정) 분할은 경보 커트라인과 확률 보정을 정하는 전용 구간입니다.

출력: 분할 경계 인덱스 4쌍 (분 경계에 정렬)

3 피쳐 생성 (fit_feature_state → build_features)

거래마다 42개 숫자 피쳐를 만듭니다: 금액 정규화 6종(학습 구간 통계로만 적합), 통화·결제수단 해시 인코딩 24종(어떤 데이터셋이 와도 차원 고정), 상대 시간 12종(직전 거래로부터의 경과·최근 1h/24h 빈도 — 전부 과거만 참조). 통계 객체(FeatureState)는 JSON으로 직렬화되어 서빙 시 재사용됩니다.

출력: (5,078,336 × 42) 피쳐 행렬 + FeatureState

4 그래프 윈도우 구성 (make_ranges → build_causal_window)

거래를 "판정 대상 5만 건 + 과거 컨텍스트 10만 건" 묶음으로 자르고, 묶음마다 그래프를 만듭니다. 핵심 규칙: **그래프에는 과거 컨텍스트만 들어가고 판정 대상은 들어가지 않습니다**. 이 규칙이 지켜졌는지 assert(자동 검사)가 매 윈도우 확인합니다. 미래 정보를 쓰는 실수를 코드 수준에서 차단한 것입니다.

출력: 윈도우별 그래프 텐서 묶음 (노드 피쳐·엣지·병렬 엣지 그룹·대상 거래)

5 하이퍼파라미터 스위프 (run_weight_sweep)

불균형 보정 가중치 후보 {5, 15, 30}을 각각 12에폭 파일럿 학습해 검증 성적(평균 70% + 최악 시기 30%)으로 하나를 고릅니다. 이 선택에 calib/test 데이터는 관여하지 않습니다.

출력: 선택된 cap + pos_weight_sweep.csv · 소요 참고: 파일럿 1회 ≈ 7.2분 (기록 기준)

6 본학습 × 시드 3개 (train_model)

같은 설정으로 난수 시드만 바꿔 3번 학습합니다(최대 50에폭, 조기종료). 학습 중에는 "잘 못 맞추는 시기의 데이터에 가중치를 더 주는" GroupDRO와, 지름길 피처를 확률적으로 지우는 shortcut dropout이 함께 돌아 일반화를 강화합니다.

출력: 모델 가중치 3개 (`HI-Small_seed{0,1,2}.pt`)

7 앙상블·보정·임계값 확정 (ensemble_logits → fit_temperature)

3개 모델의 출력을 평균(앙상블)하고, calib 구간에서 확률을 보정(temperature scaling)한 뒤 경보 커트라인 2종 — F1 최적 임계값과 **경보 예산 임계값(전체 거래의 상위 0.1%만 경보)** — 을 확정합니다. 이후 이 값들은 고정 상수입니다.

출력: temperature(상수 1개) + threshold 2개 → `manifest.json` 에 기록

8 평가·모니터링 리포트·저장

test 구간을 1회 평가(신뢰구간 포함)하고, 그래프 없는 대조 모델(GBT)과 비교하고, 계좌 위험도 상위 1,000건 ·드리프트 리포트·세트 간 zero-shot 결과·전체 설정 manifest를 파일로 저장합니다.

출력: `artifacts_v7/` 폴더 전체 (§3의 명세)

비 ML 팀원을 위한 파이프라인 요점 세 가지

- ① 모든 통계·커트라인은 "그 시점까지의 데이터"로만 계산됩니다 — 운영에서 그대로 재현 가능한 절차입니다.
- ② 학습의 최종 산출물은 코드가 아니라 **파일 묶음(모델 3개 + manifest)**이고, 서빙은 이 파일만 있으면 됩니다.
- ③ 임계값·확률 보정값은 모델과 함께 배포되는 **버전 관리 대상**입니다 — 모델만 바꾸고 임계값을 안 바꾸면 사고가 납니다.

2. 모델 구축 — 컴포넌트 관점으로

모델 이름은 **CausalMegaGNN**입니다. 내부는 딥러닝이지만, 연동 관점에서는 "텐서 묶음을 받아 로짓(점수)을 내는 순수 함수"로 보면 충분합니다.

2-1. 입출력과 규모

항목	내용
입력	윈도우 그래프 텐서 묶음 — 노드 피쳐(계좌당 9개 숫자), 컨텍스트 엣지(거래당 44개 숫자), 판정 대상 거래 피쳐(42개 숫자), 병렬 엣지 그룹 인덱스
출력	대상 거래별 로짓(실수 점수) + 계좌별 보조 로짓. 로짓은 이후 보정 상수 T로 나눠 sigmoid를 통과시키면 확률이 됩니다
규모	hidden 128 × 3층. 파라미터 수십만 개 수준(참고: 같은 hidden/층의 v6 모델이 356,740개) — 가중치 파일은 수 MB로 가볍습니다 . 서버 병목은 모델 크기가 아니라 그래프 구성(전처리) 쪽입니다
배포 단위	동일 구조 모델 3개 (시드 앙상블) — 요청당 forward 3회 후 로짓 평균. 지연이 빠듯하면 1개만 서버하는 옵션도 있습니다(성능은 소폭 하락, v6 측정 기준 앙상블 지연 1.3 배)
정밀도	bf16 혼합정밀 우선(미지원 GPU는 fp16 + GradScaler로 자동 풀백). 수치 이상(non-finite) 발생 시 fp32 재시도 → 진단 예외의 3단 방어 내장

2-2. 왜 이런 구조인가 — 세 가지만 기억하십시오

첫째, "과거만 본다"가 구조에 박혀 있습니다. 판정 대상 거래는 그래프에 넣지 않고 마지막 판정 단계(readout)의 재료로만 씁니다. 그래서 학습 때의 조건과 운영 때의 조건이 같습니다 — "학습에선 잘 됐는데 운영에서 안 되는" 사고의 주 원인 하나를 구조적으로 제거했습니다.

둘째, 거래량 많음 ≠ 의심이 되도록 집계를 평균으로 했습니다. 은행·시기마다 거래량 분포는 다릅니다. 단순 합산 모델은 "거래가 많은 계좌 = 위험"이라는 지름길을 배우기 쉬워서, 병렬 거래를 계좌쌍 단위로 평균 → 이웃 단위로 평균하는 2단계 집계로 바꾸고 거래량은 별도의 통제된 항으로만 넣었습니다.

셋째, 판정 헤드는 거래용과 계좌용 두 개입니다. 주 출력은 거래 위험도이고, 계좌 위험도는 보조 출력 + 사후 집계(계좌별 $0.7 \times \text{최대} + 0.3 \times \text{평균}$)로 만듭니다. 케이스 화면에서 "이 계좌 자체의 위험도"를 보여줄 수 있는 근거 데이터가 여기서 나옵니다.

3. 산출물(아티팩트) 명세 — 서빙에 필요한 파일들

학습 파이프라인이 끝나면 `artifacts_v7/` 폴더에 다음 파일들이 생성됩니다. 굵게 표시한 4종이 서빙 필수 세트이고, 나머지는 분석·대시보드용입니다.

파일	내용	소비 주체
HI-Small_seed0/1/2.pt	모델 가중치 3개 (PyTorch state_dict)	BE 추론 서비스
manifest.json	실험 전체의 단일 진실 소스 — 설정값, 피쳐 통계(FeatureState), 피쳐 이름/인덱스, 분할 경계, 선택된 가중치 cap, temperature, 임계값 2종 , 테스트 지표, 인과 계약 문구까지 한 파일에 기록	BE(서빙 파라미터 로드) · 전원(재현성 근거)
pos_weight_sweep.csv	하이퍼파라미터 스윙 원표	AI 파트, 리포트
cross_set_results.csv	세트 간 zero-shot 평가 결과	AI 파트, 리포트
drift_report.csv	드리프트 신호별 값과 OK/WARN/CRITICAL 상태	대시보드(FE) · 모니터링(인프라)
top_accounts.csv	계좌 위험도 상위 1,000건 (계좌, 최대/평균 점수, 거래 수)	케이스 큐·계좌 화면(FE/BE)
ablation.csv (옵션)	구성요소별 기여도 실험 결과 (실행 시)	AI 파트

manifest.json이 중요한 이유

서빙 코드에 임계값·보정값을 하드코딩하지 않고 manifest에서 읽게 하면, **모델 교체 = 파일 4종 교체**로 끝나고 배포 이력이 곧 감사 기록이 됩니다. 노트북에도 "설계가 바뀌면 새 experiment id를 만들라"는 규율이 명시되어 있습니다 — 감사 로그가 필수인 AML 도메인 특성과 맞는 운영 방식입니다.

4. 운영(서빙) 흐름은 이렇게 됩니다

노트북의 학습·평가 구조를 운영으로 옮기면 아래 흐름이 됩니다. 팀 화두 결정(분 단위 배치, 사후 탐지)과 v7의 인과 구조를 합친 것으로, ①~⑦ 순서 자체가 노트북의 평가 코드와 동일해 학습-서빙 괴리가 없습니다.

[신규 거래 스트림] —(1분 단위로 묶음)—▶ ① 표준화: 필수 9컬럼 매핑 (canonicalize와 동일 규칙)

② 피쳐 42종 계산 ← manifest의 FeatureState(금액 통계) + 과거 거래 버퍼(최근 10만 건)

③ causal window 구성 ← 그래프에는 과거 버퍼만, 신규 배치는 판정 대상으로만

④ 모델 3개 forward → 로짓 평균 (GPU, bf16)

⑤ 확률 보정: sigmoid(로짓 / temperature)

⑥ 임계값 비교 → 경보 플래그 (F1 임계값 또는 경보 예산 임계값 — 운영은 예산 방식 권장)

⑦ 결과 적재: 거래 위험도 → 알림/케이스 큐 · 계좌 위험도 집계 · 드리프트 지표 갱신

상태 관리가 필요한 것은 **과거 거래 버퍼(슬라이딩 윈도우, 최근 10만 건)** 하나입니다. 피쳐와 그래프가 전부 "과거만 참조"라 이 버퍼만 유지되면 온라인 계산이 가능합니다. 경보 예산 임계값을 권장하는 이유는 조사 인력이 하루에 처리할 수 있는 케이스 수가 고정이라는 운영 현실 때문이며, **임계값이 calib에 고정되어 있으므로 실제 경보율이 예산(0.1%)에서 벗어나는 것 자체가 드리프트 경보 신호**가 됩니다 — 모니터링 지표가 공짜로 하나 생기는 구조입니다.

지연 참고치: v7 프로토콜의 추론 지연은 아직 측정 전입니다. 구조가 유사한 v6 측정에서는 분 단위 배치 기준 앙상블이 단일 모델의 약 1.3배였습니다(6_generalized_fixed §17). 정확한 SLA 산정은 v7 본학습 완주 후 동일 방식으로 측정해 공유하겠습니다.

5. 팀별 연동 포인트

FE 화면에 쓸 수 있는 데이터가 이렇게 나옵니다

프로젝트 핵심 기능 기준으로 매핑하면: **알림/케이스 큐**에는 경보 플래그된 거래의 위험도 확률(보정된 값이라 "위험도 92%"로 그대로 표기 가능)·임계값·거래 기본 정보가, **케이스 상세**에는 판단 근거로 쓸 신호들(최초 거래 여부, 최근 1h 송금 건수, 통화 불일치, 자기송금 등 — v6의 조사노트 JSON-STR 초안 모듈이 이 필드들을 이미 정의해 두었습니다)과 관계 서브그래프용 원천(대상 거래 주변의 과거 컨텍스트 거래 목록)이, **계좌 조회**에는 `top_accounts.csv`의 계좌 위험도가 대응됩니다. **메인 대시보드**에는 일별 경보 건수·경보율과 함께 `drift_report.csv`의 OK/WARN/CRITICAL 상태를 "모델 건강" 위젯으로 노출하는 것을 권장합니다. 위험도는 확률(0~1)이므로 색상 매핑 시 임계값 2종(F1·예산)을 경계로 쓰시면 됩니다.

BE 인터페이스 계약과 서빙 구조

입력 계약: 모델이 요구하는 것은 거래당 필수 9필드입니다 — `timestamp`, `src`(은행|계좌), `dst`, `amount_paid`, `amount_received`, `payment_currency`, `receiving_currency`, `payment_format` (+학습 시에만 `is_laundering`). 실패데이터 스키마를 이 9필드로 매핑하는 어댑터가 BE 쪽 첫 과제입니다. 누락 필드는 모델 파이프라인이 즉시 예외를 던지도록 되어 있으니 어댑터 단계에서 검증해 주십시오. **상태:** 최근 거래 버퍼(10만 건)와 분 단위 배치 큐가 필요합니다. **파라미터:** `temperature`·임계값·피쳐 통계는 코드가 아니라 `manifest.json`에서 로드하십시오(\$3). 채점 응답을 프로젝트 API 컨벤션에 맞추면 예를 들어 다음 형태가 됩니다:

```
{
  "statusCode": 200,
  "timestamp": "2026-08-10T14:03:00+09:00",
  "path": "/transactions/1204/risk",
  "message": "scored",
  "data": {
    "transaction_id": 1204,
    "risk_score": 0.9231,           // 보정된 확률 (sigmoid(logit/T))
    "flagged": true,
    "threshold_used": "budget",   // "budget"(경보 예산) | "f1"
    "threshold_value": 0.6768,
    "model_version": "v7-strict-causal-research", // manifest의 version
    "account_risk": { "src": 0.87, "dst": 0.41 }
  },
}
```



```
"error": null
```

```
}
```

필드 구성은 v6 조사노트 JSON과 v7 manifest의 키를 조합한 **제안**이며, 확정은 API 설계 회의에서 하면 됩니다. 감사 로그 요구사항과 연결할 것: 어떤 모델 버전·임계값으로 판정했는지를 응답과 함께 저장하면 규제 대응 근거가 됩니다.

인프라 자원·모니터링 요구사항

학습: GPU 1장으로 충분합니다. 참고 실측 — 스왑 파일럿 1회 7.2분(기록 기준), 구조가 유사한 v6는 4시드 전체 학습이 11.4분(V100급)이었습니다. v7 전체(스왑 3회 + 본학습 3시드 50에폭)는 이보다 길지만 시간 단위이지 일 단위가 아닙니다. bf16을 쓰므로 **Ampere(A100/RTX30) 이상 권장**이며, 미지원 GPU에서는 fp16 경로로 자동 폴백됩니다. **서빙:** 모델 자체는 수 MB로 가볍고, 메모리를 쓰는 것은 그래프 구성(윈도우당 노드 ~18만·엣지 ~30만 규모)입니다. **모니터링:**

drift_report.csv의 신호들(score PSI 경고 0.10/위험 0.25, 경보율 비율 1.5/2.0, ECE 0.02/0.05 등)을 메트릭 시스템에 그대로 옮기면 임계값까지 정의된 알람 셋이 됩니다. 라벨(정답)이 늦게 도착해도 동작하는 지표들로 설계되어 있습니다.

6. 미결정 사항과 필요한 결정

항목	상태	누가 결정/실행
v7 본학습 완주	업로드본에는 스왑 파일럿까지만 실행 기록 존재 — 최종 성능 수치는 아직 없습니다. 완주 후 test 지표·지연 측정치를 이 보고서 개정판으로 공유하겠습니다	AI 파트
서빙 프레임워크	미정 (노트북은 학습·평가까지만). §4 흐름을 담은 추론 서비스 형태(예: FastAPI+Torch, 배치 잡) 결정 필요	BE + AI 합의
실데이터 스키마 매핑	필수 9필드 어댑터 + 계좌 식별 규칙(entity resolution) — 노트북도 "배포 전 별도 검증" 항목으로 명시	BE
운영 임계값 정책	F1 방식 vs 경보 예산 방식(권장) — 조사 인력 처리량과 연동해 예산 비율(현재 0.1%) 확정 필요	기획 + 컴플라이언스
세트 간 일반화 검증	LI-Small 등 데이터 파일 미확보로 zero-shot 평가 대기 중 — "일반화 모델" 주장의 전제 조건	AI 파트 (데이터 확보 협조)
STR 초안 LLM 연계	v6에 규칙 기반 초안 + LLM 슬롯 존재. 수치·계좌 번호는 원본 고정 제약 필수	AI + BE (MVP 이후)

7. 출처

본 보고서의 파이프라인·모델·산출물 서술은 `AML_GNN_edge_classification_7_research_gradeeeee.ipynb`의 코드와 저장된 실행 출력을, 지연 측정치·조사노트/STR 필드는

`AML_GNN_edge_classification_6_generalized_fixed.ipynb`의 실행 출력을 근거로 합니다. API 응답 형식은 자금세탁소 프로젝트 컨벤션(응답 형식 규칙)을 따랐고, 화면 매핑은 프로젝트 핵심 기능 정의(메인 대시보드·알림/케이스 큐·케이스 상세·STR 모듈)를 기준으로 했습니다. §5의 API 필드 구성과 서빙 프레임워크 관련 내용은 노트북에 없는 **제안**이며 본문에 그렇게 표시했습니다. 결과가 기록되지 않은 수치는 "미측정/미기록"으로 명시했고 추정치를 쓰지 않았습니다.

개발자용 상세 문서: 「**AML GNN 노트북 7종 코드 설명서**」(버전 전체 이력), 「**AML GNN v7 상세 설명서**」(v7 코드 수준 해부) — 프로젝트에 함께 저장되어 있습니다.