

프로젝트 기획서

팀명	기업-17(자금세탁소)		
팀원 및 역할	■ 팀장 : 송동현 (PM, Infra) ■ 팀원 : 박지원 (QA, BE) - 김명기 (FE, UI/UX) - 김태훈 (AI, Data) - 손은총 (AI, Data):		
주제 구분	✓기업 □자율	기업명/멘토명	모름/윤상범
아이디어 주제	그래프 신경망 기반 자금세탁방지(AML) 의심거래 탐지		
제안 배경 및 필요성	제안 배경 자금세탁은 하나의 계좌나 금융기관 안에서만 이루어지지 않는다. 자금은 여러 계좌로 분산하거나, 복수의 금융기관을 거쳐 이동시키고, 다시 특정 계좌로 집중시키는 등 다양한 거래 관계를 통해 자금 출처와 이동 경로를 은폐한다. FATA(국제자금세탁방지기구)는 범죄수익을 작은 금액으로 분할하여 금융시스템에 투입하거나, 자금의 출처와 거리를 두기 위해 여러 계좌와 금융기관을 거쳐 반복적으로 이동시키는 과정을 대표적인 자금세탁 방식으로 설명한다. 이처럼 거래가 여러 단계와 계좌로 분산될 경우, 개별 거래만으로는 전체 자금 흐름과 거래 간 연관성을 파악하기 어렵다. 따라서 개별 거래의 금액이나 빈도만으로 판단하기보다, 계좌와 금융기관 사이에 형성된 전체 거래 관계와 시간에 따른 자금 흐름을 함께 분석할 필요가 있다. 현재 금융기관은 자체적으로 보유한 거래내역을 바탕으로 룰 기반 탐지와 이상거래 탐지 모델을 운영한다. 그러나 기관별로 데이터 구조, 탐지 기준, 위험 임계값이 다르고 분석 가능한 거래 범위도 각 기관 내부로 제한될 수 있다. 이로 인해 여러 금융기관에 걸쳐 분산, 순환, 집중되는 자금 흐름은 각 기관의 관점에서 정상적인 개별 거래처럼 보이거나, 동일한 자금 흐름에서 발생한 거래가 서로 다른 의심거래와 Alert로 분리될 가능성이 있다. 금융정보분석원과 같은 중앙 AML 분석기관은 금융회사로부터 의심거래보고를 수집,분석하고 자금세탁과 관련성이 있다고 판단되는 정보를 법집행기관에 제공한다. 따라서 기관별로 생성된 위험 신호를 종합하고, 서로 연관된 거래를 하나의 자금 흐름으로 연결하며, 조사 필요성이 높은 대상을 우선적으로 선별할 수 있는 분석 체계가 중요하다. 그래프 신경망은 계좌와 금융기관을 노드로, 거래를 엣지로 표현하여 개별 거래의 속성뿐 아니라 주변 계좌와의 연결 관계, 다단계 자금 이동, 분산과 재집중, 순환 거래와 같은 구조적 특징을 함께 학습할		

수 있다. 이는 기존 룰이나 단건 중심 분석을 완전히 대체하기보다는, 여러 기관과 계좌에 걸쳐 나타나는 관계형 자금세탁 패턴을 보완적으로 탐지하는 방법으로 활용할 수 있다.

이에 본 프로젝트는 IBM AML 거래 데이터를 이용해 여러 금융기관과 계좌가 연결된 거래환경을 구성하고, 그래프 기반 모델을 통해 관계형 자금세탁 패턴과 위험 신호를 탐지하고자 한다. 또한 서로 연관된 거래를 하나의 Episode 단위로 묶어 위험도, 탐지 근거, 관련 거래 흐름을 중앙 분석 담당자에게 제공함으로써 조사 대상의 우선순위 결정과 전체 자금 흐름 파악을 지원하고자 한다.

본 프로젝트는 실제 자금세탁 여부를 자동으로 확정하거나 기존 AML 시스템을 목적으로 하지 않는다. **개인정보와 KYC정보가** 포함되지 않는 합성데이터를 활용하여 다기관 관계 분석의 기술적 가능성을 먼저 검증하고, 향후 가명화, 데이터 표준화, 기관별 접근 통제 및 정보 보호를 고려한 중앙 AML 분석체계로 확장할 수 있는 기반을 마련하는 것을 목표로 한다.

- **개인정보:** 이름, 주민등록번호, 연락처 등 개인을 식별할 수 있는 정보

- **KYC 정보:** 고객확인을 위해 수집하는 신원, 직업, 거래 목적, 자금 출처, 실소유자, 고객위험등급 등의 정보

시장현황

자금 세탁은 금융 기관이 지속해서 대응해야 하는 국제적인 금융범죄 문제이다. FATF는 2024년 G20회의에서 UN 추정치를 인용해 불법 수익 규모가 전 세계 **GDP의 약 2~5%**에 해당한다고 밝혔다. 이는 자금 세탁방지 업무가 일시적인 대응이 아니라 지속적인 제도 운영과 금융정보 분석이 필요한 영역임을 보여준다.

- FATF, G20 Finance Ministers and Central Bank Governors Meeting, 2024

국내에서도 의심거래보고가 지속해서 증가하고 있다. 금융위원회 자료에 따르면 전체 의심거래보고(STR)는 2022년 822,644건에서 2023년 906,462건, 2024년 1,084,143건으로 2024년 보고 건수는 전년 대비 19.6%, 2022년 대비 약 31.8% 증가한 수치이다. 이는 중앙 분석기관이 검토하고 연계해야 하는 의심거래 정보의 규모가 계속 확대되고 있음을 보여준다.

- 금융위원회, 정부업무평가 2024년 자체평가 결과보고서

국내 금융권에서도 기존 룰 중심 시스템에 AI를 결합하려는 시도가 진행되고 있다. 신한은행, 하나은행, Sh수협은행 같은 여러 금융 기관에서도 기존의 룰 기반 탐지에서 AI를 결합하려는 시도가 진행되고 있다.

- <https://hit.hanati.co.kr/m/ko/about/press/view?seq=57>

- 신한금융그룹 2022 ESG 보고서 p112

서비스 필요성

금융기관별로 생성되는 의심거래보고와 위험 신호는 개별 거래 또는 기관 단위로 관리되기 때문에, 동일한 자금 흐름과 관련된 거래가 여러 건의 Alert로 분리될 수 있다. 특히 자금이 여러 금융기관과 계좌를 거쳐 이동하는 경우 중앙 분석 담당자가 기관별 정보를 수작업으로 연결하고 전체 자금 흐름을 파악해야 하므로, 조사 대상이 증가할수록 분석의 복잡성과 업무 부담도 커질 수 있다.

또한 BIS Innovation Hub와 관련 연구에서는 기존 AML 거래 모니터링 시스템이 생성한 Alert 중 약 90~95%가 조사 후 정상으로 종결되는 오탐으로 추정된다고 보고하였다. 높은 오탐률은 조사 인력이 실제로 위험 거래보다 반복적인 Alert 검토에 많은 시간을 사용하게 하는 원인이 된다고 한다.

이에 기관별 거래를 통합하여 기관과 계좌를 넘나드는 관련 거래를 하나의 Episode Alert로 구성할 필요가 있다. 이를 통해 중앙 분석 담당자는 개별 거래를 반복적으로 검토하는 대신 전체 자금 흐름과 연관 계좌를 함께 확인하고, 위험도가 높은 Episode부터 우선적으로 분석할 수 있다. 서비스는 위험 신호의 출처와 유형, 모델 점수, 거래 관계, 데이터 제공기관, 모델·설정 버전 및 처리 이력을 함께 제공하여 분석 결과의 설명 가능성과 추적성을 확보한다. 생성된 Episode Alert는 1차 분석과 심층 분석을 거쳐 필요한 경우 사건화 또는 법집행기관 제공 검토로 연결된다. 탐지 결과는 자금세탁 여부를 자동으로 확정하는 판단이 아니라, 담당자가 추가 분석 필요성과 조사 우선순위를 결정하도록 지원하는 위험 신호로 활용한다.

초기 단계에서는 IBM AML 데이터를 활용하여 개인정보와 KYC 정보 없이 다기관 거래환경을 모사하고, 관계형 거래 탐지, Episode 구성 및 중앙 조사 지원 기능의 기술적 가능성을 검증한다. 이후에는 가명화된 계좌 식별체계, 기관별 접근통제, STR 정보 연계, 외부 정보 및 법집행기관 시스템 연계를 고려할 수 있는 확장 기반을 마련하고자 한다.

근거 자료

- [BIS Innovation Hub, Project Aurora: The Power of Data, Technology and Collaboration to Combat Money Laundering, 2023](#)
- Öztas et al., *Transaction Monitoring in Anti-Money Laundering: A Qualitative Analysis and Points of View from Industry*, Future Generation Computer Systems, 2024. [논문 원문](#)

유사 제품 현황 및 비교

1. UNODC goAML

1.1 주요 기능 및 장점

- STR·CTR 접수 룰·위험점수 분석, 관계 그래프, Case관리, 법집행기관

	정보 제공 및 감사 이력 1.2 주요 대상 - 국가 FIU·중앙분석기관 1.3 우리 프로젝트와의 관계 - 가장 직접적인 벤치마크, 중앙기관 업무 전반을 지원하지만, 본 프로젝트는 거래 내역을 기반으로 GNN 위험도 산출과 Alert 생성에 집중 2. Oracle FCCM 2.1 주요 기능 및 강점 - 거래 모니터링, KYC·고객위험평가, 시나리오 튜닝, 그래프 분석, 통합 Case 관리 및 규제 보고 2.2 주요 대상 - 은행·대형 금융기관 2.3 우리 프로젝트와의 관계 - 종합 AML플랫폼 벤치마크, 본 프로젝트는 전체 기능을 대체하지 않고 관계형 탐지 영역을 검증 3. SAS Anti-Money Laundering 3.1 주요 기능 및 강점 - 룰과 AI·ML 결합, 네트워크 분석, 엔티티 연결, 고객 단위 Alert 통합, Case 관리 및 규제보고 3.2 주요 대상 - 은행·금융기관 3.3 우리 프로젝트와의 관계 - 네트워크 기반 탐지 및 Alert 통합 방식의 벤치마크 4. GTOne AMLXpress 7-Octa AML-PRISM 4.1 주요 기능 및 강점 - 국내 AML 규정에 맞춘 거래 모니터링, 고객위험평가, STR 및 Case 관리 4.2 주요 대상 - 국내 금융기관 4.3 우리 프로젝트와의 관계 - 국내 규제·업무 프로세스 벤치마크 5. Flagright 5.1 주요 기능 및 강점 - 노코드 룰 생성, 과거 데이터 시뮬레이션, Shadow Mode, 임계값 추
--	---

	천 5.2 주요 대상 - 핀테크·금융서비스 기업 5.3 우리 프로젝트와의 관계 - 룰 생성·검증·튜닝 기능의 벤치마크 6. Lucinity 6.1 주요 기능 및 강점 - 다양한 Alert 통합, Case 분리·병합·위임, Customer 360, 협업 및 감사 이력 6.2 주요 대상 - AML 조사·컴플라이언스 조직 6.3 우리 프로젝트와의 관계 - Episode 조사 화면과 업무 흐름의 벤치마크 본 프로젝트의 차별성은 여러 금융기관의 거래 파일 수집부터 거래 단위 위험예측, 추론 결과를 바탕으로 한 관련 거래 서브그래프·Alert 생성, L1 검토와 L2 Episode 조사까지의 흐름을 하나의 PoC로 검증하는 데 있다.
제안 내용	개발 목표 - 증가하는 의심거래를 분석하는 중앙 AML 기관을 대상으로, 여러 금융기관의 거래 관계를 그래프로 분석하고 연관 거래를 Episode 단위로 제공함으로써 조사 우선순위 선정과 자금 흐름 파악의 효율성을 높인다. 개발 내용 거래 데이터 통합 서비스 (MVP) - 은행별 거래 CSV를 S3에 업로드하고 파일별 수신 완료 상태를 확인하는 기능 - 누락·형식 오류·중복을 검증하고 계좌·거래 식별자를 가명화하는 기능 - 기관별 거래를 표준화·통합하여 분석용 파일을 S3에 저장하는 기능 - 계좌를 노드, 거래를 방향과 시각을 가진 연결로 표현하여 거래 단위 모델 입력을 준비하는 기능 AI 거래 탐지 서비스 - 거래별 자금세탁 위험도를 산출하는 이진분류 모델 개발 - 정상거래·자금세탁 패턴·무패턴 자금세탁을 구분하는 유형분류 모델 개발 - 두 모델을 병렬 적용하여 거래별 위험 점수와 탐지 유형 생성 - Job ID와 모델 입력 파일의 Presigned GET URL, 결과 저장용 Presigned PUT URL을 GPU 서버에 전달하는 기능 - 모델 결과의 거래 ID·건수·버전·점수 형식을 검증하고 DB에 저장하는 기능

	- 모델별 임계값·버전·추론 이력 및 Job 단계별 상태 관리 기능 - 클래스 불균형에 대한 학습 방법을 비교하고 모델별 성능을 평가하는 기능 Alert 구성 및 Episode 이관 서비스 (MVP) - 거래별 추론 결과에서 위험 거래를 선정한 후, 통합 거래 데이터에서 관련 계좌·거래를 찾아 조사용 서브그래프를 생성하는 기능 - 시간·계좌·기관·거래 경로를 고려해 관련 거래를 Alert로 구성하는 알고리즘 1종 구현 - Alert별 씨앗 거래, 연결 거래, 위험 점수, 탐지 유형 및 연결 근거 제공 - L1 담당자가 추가 조사가 필요한 거래 범위를 새 Episode 또는 기존 Episode로 이관하는 기능 - Episode별 포함 Alert, 주요 거래·계좌·참여기관 및 조사 범위 제공 증양 조사 관리 서비스 (MVP) - L1의 Alert 1차 검토와 L2의 Episode 심층 조사를 구분한 2단계 업무 기능 - L1의 정상·오탐 처리, 검토 의견 기록 및 심층조사 이관 기능 - L2의 관계 그래프 조회, 조사 소견·판정 기록 및 Episode 종결 기능 - Alert·Episode 담당자 배정과 운영 관리자의 재배정 기능 - 담당자·상태·조사 의견·처리 시각을 포함한 감사 이력 관리 기능 - 트 기능 룰 기반 탐지 서비스 (MVP 이후) - 고액 반복, 분할 거래, 다수 계좌 분산, 단기간 재집중, 순환 거래 등 기본 룰 구현 - IF/THEN 방식의 룰 생성·수정, 임계값·버전 관리 및 과거 거래 백테스트 - 룰별 탐지 결과와 AI 결과의 결합 및 성능 비교 대시보드 및 시각화 서비스 (MVP) - 개인 담당 업무·기관 전체 분석 대시보드 - 통합 거래 목록·상세 화면 - Alert 목록·상세 및 L1 검토 화면 - Episode 목록·상세 및 L2 조사 화면 - 관련 거래 서브그래프·다기관 자금 흐름 화면 - 기관별 파일 수신·분석 Job 상태 화면 총 6종 이상의 핵심 화면 구현 성능 및 품질 평가 (MVP·PoC) - 이진분류: Precision, Recall, F1-score, PR-AUC 평가 - 유형분류: Macro-F1 및 유형별 Precision·Recall 평가 - 조사 가능량 기준: 상위 위험 거래의 Precision@K·Recall@K 평가 - Alert 구성 품질: 라벨로 연결 관계를 확인할 수 있는 거래를 기준으로 연관 거래 포함률·비관련 거래 혼입률 평가 - 시스템 품질: 파일 수신부터 Alert 생성까지의 처리 시간, 데이터 누락 및 중복 생성 건수 평가
수행 방법	데이터 확보 방안 - 데이터셋 : IBM Transactions for Anti Money Laundering(AML) - 출처: https://www.kaggle.com/datasets/ealtman2019/ibm-transactions-for-anti-money-laundering-aml

데이터 출처

- 데이터셋: IBM Transactions for Anti Money Laundering
- 제공처: IBM 공개 합성 AML 데이터
- 다운로드: [Kaggle 데이터셋](#)
- 라이선스: CDLA-Sharing 1.0

해당 데이터는 실제 개인정보를 가명화한 데이터가 아니라, 은행·개인·기업의 거래환경을 가상으로 생성한 합성데이터이다. [IBM AML-Data 설명](#)

데이터 수집 방법

- Kaggle에서 공개 데이터셋 직접 다운로드
- 필요할 경우 Kaggle API를 이용하여 데이터셋별 자동 다운로드
- HI-LI와 Small-Medium-Large로 구분된 총 6개 데이터셋 활용

데이터 종류	파일명 예시	유형·형식	중요 내용
거래 데이터	HI-Small_Trans.csv	정형 데이터·CSV	거래 시각, 송금·수취 은행과 계좌, 금액, 통화, 결제방식, 자금세탁 여부
계좌 데이터	HI-Small_accounts.csv	정형 데이터·CSV	은행 및 계좌 식별정보와 계좌 관련 속성
패턴 데이터	HI-Small_Patterns.txt	텍스트 데이터·TXT	자금세탁 거래가 포함된 8종 패턴과 패턴별 관련 거래정보

라벨링 형식

- 거래 데이터의 Is Laundering 컬럼을 이용한 이진 라벨
 - 0: 정상거래
 - 1: 자금세탁 거래
- 패턴 데이터를 거래 데이터와 연결하여 9-Class 라벨 생성
 - 8종 패턴
 - 정상거래 1종

패턴 종류




Figure 2: Laundering Patterns Modelled

출처:

Altman et al., *Realistic Synthetic Financial Transactions for Anti-Money Laundering Models*, NeurIPS 2023

데이터 규모

데이터셋	기간	계좌 수	전체 거래	자금세탁 거래	자금세탁 비율
HI-Small	약10일	약 51.5만	약 500만	약5.1천	약0.102%

LI-Small	약10일	약 70.5만	약 700만	약4천	약0.052%
HI-Medium	약16일	약 207.7만	약 3,200만	약3.5만	약0.110%
LI-Medium	약16일	약 202.8만	약 3,100만	약1.6만	약0.051%
HI-Large	약97일	약 211.6만	약 1억 8천만	약22.3만	약0.124%
LI-Large	약97일	약 206.4만	약 1억 7,600만	약10만	약0.057%

목표 및 성과지표

IBM AML 데이터는 정상거래에 비해 자금세탁 거래의 비율이 매우 낮은 클래스 불균형 데이터이다. 따라서 전체 정확도(Accuracy)는 모델의 실질적인 탐지 성능을 과대평가할 수 있으므로, F1-score, PR-AUC, Recall 및 Precision을 중심으로 성능을 평가한다.

1. 이진분류 성능지표

이진분류 모델은 각 거래의 정상·자금세탁 여부와 자금세탁 위험점수를 산출한다.

핵심 성능지표

- 자금세탁 클래스 F1-score
- PR-AUC

1차 목표

- 자금세탁 클래스 F1-score 0.60 이상
- PR-AUC가 XGBoost 기준모델 이상

운영 성능지표

- Recall@Top K%
- Precision@Top K%

F1-score 목표는 동일한 IBM AML 데이터셋을 이용한 NeurIPS 2023 연구결과를 참고하여 설정

Recall@Top K%와 Precision@Top K%는 모델이 산출한 위험점수 상위 거래만 검토했을 때의 탐지 성능을 측정한다. 실제로 조사할 수 있는 거래 비율은 운영기관의 인력과 환경에 따라 달라질 수 있으므로, K값을 하나로 확정하지 않고 상위 0.1%, 0.5%, 1% 등 여러 구간에서 성능을 비교한 후 적절한 운영 기준을 결정예정

2. 패턴분류 성능지표

패턴분류 모델은 정상거래와 8종의 자금세탁 패턴을 구분하는 9-Class 분류를 수행한다.

핵심 성능지표

- Macro-F1

비교 목표

- 가장 높은 성능을 보인 기준모델보다 Macro-F1 0.05 이상 향상
- 기준모델 : GNN을 사용하지 않은 모델(LightGBM, XGBoost)

세부 분석지표

- 패턴별 Precision·Recall·F1-score
- Confusion Matrix

현재 동일한 9개 클래스와 평가 조건을 사용한 직접적인 외부 벤치마크가 부족하기 때문에, 거래 속성과 과거 거래 집계 피처를 사용한 XGBoost 모델을 내부 기준모델로 구축한다.

이후 GNN 모델의 Macro-F1이 기준모델보다 0.05, 즉 5%p 이상 향상 되는 것을 비교 목표로 설정한다.

전체 Macro-F1뿐만 아니라 패턴별 Recall과 F1-score를 함께 확인하고 Confusion Matrix를 통해 모델이 어떤 패턴을 서로 혼동하는지도 확인한다.

추진 전략(일정, 수행 방법 등)

- 일정 2026.08.03 - 2026.12.11

수행 방법 :

1. 데이터 구성 및 누수 방지:

IBM AML 합성 데이터의 계좌를 노드, 거래를 송금 방향과 발생 시각을 가진 엣지로 구성한다. 데이터를 시간순으로 학습·검증·시험 구간에 나누고, 거래 예측에는 해당 시점 이전의 거래와 집계 정보만 사용한다. 자금세탁 여부와 패턴 정보는 정답 라벨로 활용한다.

2. 클래스 불균형 대응:

XGBoost·LightGBM 기준 모델을 구축한 뒤, 학습 데이터에 한해 정상 거래 다운샘플링, 의심 거래 업샘플링, 클래스 가중치, Focal Loss를 비교한다. GNN에서는 그래프의 거래 연결을 임의로 삭제하거나 복제하지 않고 학습 대상 거래의 샘플링과 손실 가중치를 조정한다. 검증·시험 데이터는 원래의 불균형 비율을 유지한다.

3. 거래 단위 GNN 개발:

계좌 간 송금 방향과 동일 계좌쌍의 반복 거래를 보존하는 방향성 다중그래프를 구성한다. 기본 GNN에 역방향 메시지 전달, 반복 거래를 구분하는 포트 정보, 순환 관계를 식별하는 구조 정보를 단계적으로 적용하고 성능 변화를 비교한다. 송·수신 계좌의 표현과 거래 금액·시각 등의 특성을 결합해 **거래 한 건마다** 위험 점수와 유형을 산출한다.

4. 시간 정보 및 Alert 구성:


과거 7일·30일 등 관찰 기간에 따른 탐지 성능을 비교하고, 필요하면 시간에 따라 계좌 상태를 갱신하는 GNN 기법을 추가 검토한다. 모델 추론이 끝난 뒤 고위험 거래를 시작점으로 시간·계좌 연결·자금 이동 방향에 맞는 연관 거래를 탐색하여 조사용 서브그래프와 Alert를 생성한다.

5. 결과 평가 및 선정:

이진 탐지는 PR-AUC·F1·상위 위험 거래의 Precision@K와 Recall@K로, 유형 분류는 Macro-F1과 유형별 Recall로 평가한다. Alert의 연관 거래 포함률·비관련 거래 혼입률과 추론 시간·GPU 메모리 사용량도 측정하

여 탐지 성능과 운영 비용을 함께 비교한다.

시스템 아키텍처



- Data: Python, Pandas, Numpy
- DB - PostgreSQL
- Backend - Spring Boot, JPA
- Frontend - React, TypeScript,
- Modeling - PyTorch, PyTorch Geometric, XGBoost, LightGBM
- Infra - AWS EC2, CR ES3, SQS, DLQ, Docker Compose, Nginx,
- CI/CD - Github Action
- 협업 - Jira, Git

기대효과 및 활용방안

기대효과

- 여러 금융기관의 거래 데이터를 통합하여 개별 금융기관에서는 파악하기 어려운 기관·계좌 간 자금 흐름을 분석할 수 있다.
- 이진분류 모델과 다중분류 모델을 병렬로 활용하여 거래별 자금세탁 위험 점수와 의심 거래 유형을 함께 제공한다.
- 고위험 거래와 연관 거래를 조사용 서브그래프 및 Alert로 구성하고, 심층 분석이 필요한 경우 Episode로 이관하여 조사 범위를 체계적으로 관리한다.
- 거래별 위험 점수를 바탕으로 우선 검토 대상을 제시하여 중앙 조사 담당자의 업무 효율을 높인다.
- 거래 관계 그래프와 탐지 유형을 함께 제공하여 담당자가 자금 흐름을 파악하고 조사 여부를 판단하는 데 도움을 준다.
- 모델 버전, 거래별 추론 결과, Alert 처리 이력을 관리하여 탐지 및 조사 과정의 **추적성**을 확보한다.
- 공개 합성 데이터로 데이터 통합부터 탐지·조사까지의 업무 흐름을 검증하여, 실제 금융정보 연계에 앞서 기술적 가능성을 확인한다.

활용방안

- 중앙 AML 분석기관의 금융기관 간 통합 거래 모니터링 체계를 검증하는 PoC로 활용한다.
- 금융기관별 거래 파일의 검증·가명화·표준화·통합 처리 구조를 검증한다.
- 중앙 조사 담당자의 Alert 우선 검토, Episode 심층 분석 및 자금 흐름 파악 업무를 지원한다.
- 향후 실제 금융기관 거래 시스템, 고객 정보 및 외부 **제재 목록**과의 연계 가능성을 검토한다.
- 대용량 거래 데이터 처리 성능을 측정하고 클라우드·GPU 환경에서의 확장 가능성을 검토한다.