

멘토용 자료

주제명 : 그래프 신경망 기반 자금세탁(AML)
의심거래 탐지

2026.10.01

목차

1. 상세 시스템 구조

- 1.1 서비스 목적과 전체 처리 흐름
- 1.2 데이터 수집과 추론 연계
- 1.3 Alert와 Episode의 관계
- 1.4 시스템 아키텍처
- 1.5 E-R Diagram

2. 활용 데이터 셋

- 2.1 데이터 구성과 기간
- 2.2 HI-Large_Trans.csv (거래 데이터)
- 2.3 HI-Large_accounts.csv 계좌
- 2.4 HI-Large_Pattens.txt

3. 데이터 주요 분석 내용

4. 모델 실험

- 4.1 전처리 과정
- 4.2 피처 추출 과정
- 4.3 데이터 샘플링
- 4.4 샘플링 결과 해석
- 4.5 이진 분류
- 4.6. 패턴 분류

5. 현재 Alert 생성 알고리즘

6. 현재 구현 상태

7. 앞으로 할일

1. 상세 시스템 구조

1.1 서비스 목적과 전체 처리 흐름

우리 서비스는 여러 금융기관의 거래를 통합하여 거래별 자금세탁 위험도와 의심 유형을 분석하고, 관련 거래를 조사 가능한 단위로 제공하는 서비스이다. 주요 사용자는 여러 금융기관에 걸친 자금 흐름을 분석하는 상위기관의 AML 담당자로 설정하였다.

목표 시스템 흐름

1. 금융기관별 거래 CSV 수신
2. S3 원본 저장 및 파일 도착 확인
3. 파일 검증·가명화·통합 → 모델 입력 파일 생성
4. GPU 서버 추론 요청 → **이진·유형분류 추론**
5. 결과 파일 검증 및 DB 저장
6. 서브그래프·Alert 생성
7. 조사 화면에서 Alert·Episode 처리

※ 금융기관 내부 시스템 연동, 의심거래보고(STR) 작성·제출, 조사 종결 이후의 후속 업무 처리는 본 프로젝트의 구현 범위에서 제외한다.

1.2 데이터 수집과 추론 연계

금융기관은 서버에서 발급한 업로드용 Presigned URL을 이용해 거래 파일을 S3에 저장한다. 시스템은 업로드 완료 통지를 받은 뒤 파일의 존재, 크기, 체크섬과 기관별 도착 상태를 확인한다.

이후 필수 항목, 자료형, 중복 및 계좌 연결 관계를 검증하고, 식별자를 일관되게 가명화하여 기관 간 거래를 연결한다. 동일 거래의 중복 보고와 실제로 반복 발생한 거래는 구분하여 처리한다.

분석 실행 시에는 대상 거래와 참고 거래를 해당 실행의 입력으로 고정한다. GPU 서버에는 작업 식별자, 모델·입력 버전, 입력 파일 다운로드 주소 및 결과 업로드 주소를 전달한다.

GPU 작업이 종료되면 결과 파일의 거래 ID 집합, 건수, 모델 버전 및 점수 형식을 검증한 후 저장한다.

저장된 결과를 바탕으로 Alert 생성 알고리즘을 통해 Alert를 생성한다.


1.3 Alert와 Episode의 관계

구분	Alert	Episode
생성 주체	시스템	AML 담당자
구성 단위	위험 거래와 주변 연결·참고 거래	서로 연관된 Alert 2건 이상
목적	검토가 필요한 거래 범위 제시	여러 Alert를 연결한 조사 범위 관리
주요 정보	위험 점수, 유형, 포함 이유, 관계 그래프	포함 Alert, 연결 근거, 주요 계좌, 조사 의견
판단의 성격	자동 생성된 조사 후보	담당자가 구성한 조사 사건

Alert와 Episode는 자금세탁 여부를 자동 확정하는 결과가 아니다. 모델 예측, 거래 포함 근거, 담당자의 조사 판단을 구분하여 저장한다.

1.4 시스템 아키텍처

그래프 신경망 기반 자금세탁방지(AML) 모니터링 시스템 · 인프라 아키텍처




기술 스택

- Data: Python, Pandas, Numpy
- DB - PostgreSQL
- Backend - Spring Boot, JPA
- Frontend - React, TypeScript,
- Modeling - PyTorch, PyTorch Geometric, XGBoost, LightGBM
- Infra - AWS EC2, CR ES3, Docker Compose, Nginx,
- CI/CD - Github Action
- 협업 - Jira, Git

1.5 E-R Diagram


1.5.1 계좌와 거래 관계

- 송금과 수취는 동일한 계좌 객체에 대한 서로 다른 관계다. 물리 테이블에서는 transactions.from_account_id와 to_account_id로 구현한다.




1.5.2 금융기관 보고 자료와 통합 거래의 출처

- 원천 보고 행과 통합 거래의 통합 관계는 DB에서 transaction_reports(tx_id, report_id, report_role)로 저장한다.




1.5.3 분석 실행과 거래별 AI 결과

- 입력 고정 관계는 analysis.input_transactions로, 거래별 추론 결과는 inference_results로 저장한다. 평가 라벨은 evaluation 스키마로 분리 관리한다.



1.5.4 Alert 근거와 조사 사건

- Episode는 별도의 테이블이 아니라 review_case.kind = Episode인 조사 사건이다. Alert와 Episode의 직접 FK는 현재 스키마에 없다.



2. 활용 데이터셋

활용 데이터 셋: IBM Transactions for Anti Money Laundering (AML)

출처

<https://www.kaggle.com/datasets/ealtman2019/ibm-transactions-for-anti-money-laundering-aml>

현재 사용 중인 데이터 셋은 IBM AML 합성 거래 데이터이다. IBM Research 연구진이 제작하고 Kaggle에 공개한 데이터셋 이고 실제 개인 금융정보를 익명화한 자료가 아니다.

주요 분석 대상은 IBM AML의 HI-Large 데이터이며, 거래 파일·계좌 파일·패턴 파일을 함께 분석하였다.

2.1 데이터 구성과 기간

파일	구성	용도
HI-Large_Trans.csv	거래 시각, 송수신 은행·계좌, 금액·통화, 결제 방식, 자금세탁 여부	거래 그래프 생성 및 이진분류 정답
HI-Large_accounts.csv	은행, 계좌, Entity 식별정보 및 명칭	계좌 연결과 소유 주체 관계 구성
HI-Large_Patterns.txt	패턴 유형, 시도 단위 정보, 소속 거래	유형분류 정답 및 패턴 관련 평가

2.2 HI-Large_Trans.csv (거래 데이터)

전체 행수 : 179,702,229건

거래 기간 :2022-08-01 00:00:00 ~ 2023-01-12 16:49:00

자금세탁 거래 수 : 225,546

Amount Paid 범위 : 0.000001 ~ 8,158,609,321,727.61

결측치 : 없음완전 중복 건수 : 150건

중복 제거 후 남은 행 : 179,702,079건

앞 5행

row_id	Timestamp	From Bank	Account	To Bank	Account.1	Amount Received	Receiving Currency	Amount Paid	Payment Currency	Payment Format	Is Laundering
0	0 2022-08-01 00:17:00	020	800104D70	020	800104D70	6794.63	US Dollar	6794.63	US Dollar	Reinvestment	0
1	1 2022-08-01 00:02:00	03196	800107150	03196	800107150	7739.29	US Dollar	7739.29	US Dollar	Reinvestment	0
2	2 2022-08-01 00:17:00	01208	80010E430	01208	80010E430	1880.23	US Dollar	1880.23	US Dollar	Reinvestment	0
3	3 2022-08-01 00:03:00	01208	80010E650	020	80010E6F0	73966883.00	US Dollar	73966883.00	US Dollar	Cheque	0
4	4 2022-08-01 00:02:00	01208	80010E650	020	80010EA30	45868454.00	US Dollar	45868454.00	US Dollar	Cheque	0

컬럼 정보

순번	컬럼	타입	설명
0	Timestamp	Datetime	거래 시각(분 단위)
1	From Bank	String	송금 은행 ID
2	Account	String	송금 계좌번호
3	To Bank	String	수취 은행 ID
4	Account.1	String	수취 계좌번호
5	Amount Received	Float64	수취 금액
6	Receiving Currency	String	수취 통화
7	Amount Paid	Float64	송금 금액
8	Payment Currency	String	송금 통화
9	Payment Format	String	거래 방식(ACH, Cheque, Credit Card 등)
10	Is Laundering	Int8	자금세탁 여부(0/1)

2.3 HI-Large_accounts.csv 계좌

전체 행수 : 2,126,855건

Entity ID 수 : 670,231

중복된 Account Number 종류 : 16,496

Account Number는 전체 데이터에서 고유하지 않으며, 같은 은행 안에서만 고유하다.

순번	컬럼	타입	설명
0	Bank Name	String	은행 이름
1	Bank ID	String	은행 ID
2	Account Number	String	계좌번호
3	Entity ID	String	계좌 소유 엔티티 ID
4	Entity Name	String	엔티티 이름(Corporation, Partnership 등)

앞 5행

	Bank Name	Bank ID	Account Number	Entity ID	Entity Name
0	Portugal Bank #500	240522	82655C500	2AA04EEC5D0	Corporation #82502
1	First Bank of Laramie	339367	8505ED380	2AA06B8AC80	Partnership #15630
2	National Bank of Helena	368763	826283D80	2AA066499F0	Corporation #12918
3	Switzerland Bank #2454	3174937	842090C80	2AA06712690	Corporation #135403
4	China Bank #561	53267	817D00980	2AA053417D0	Corporation #103595

2.4 HI-Large_Pattens.txt

전체 자금세탁 패턴 수: 16,467개

패턴 종류 : 8개




Figure 2: Laundering Patterns Modelled

패턴별 Attempt 수

패턴	Attempt 수
BIPARTITE	2,109
CYCLE	2,086
FAN-IN	2,014
FAN-OUT	2,040
GATHER-SCATTER	2,054
RANDOM	2,001
SCATTER-GATHER	2,067
STACK	2,096

3. 데이터 주요 분석 내용

3.1 전체 자금 세탁 수

구분	거래 수
전체 자금세탁 거래	225,546
패턴 자금세탁	137,936
패턴 외 자금세탁	87,610

3.2 월별 자금세탁 거래 수(중복제거X)

월	전체 거래 수	자금세탁 거래 수(라벨 1)	자금세탁 거래 비율
2022-08	59,468,136	46,040	0.0774%
2022-09	56,137,121	67,372	0.1200%
2022-10	54,821,376	75,263	0.1373%
2022-11	9,269,215	33,013	0.3562%
2022-12	6,132	3,704	60.4044%
2023-01	249	154	61.8474%


3.3 시간대별 자금세탁 거래 수

시간대	전체 거래 수	자금세탁 거래 수(라벨 1)	자금세탁 거래 비율
00시	18,653,109	6,877	0.0369%
01시	7,012,409	6,642	0.0947%
02시	6,997,571	6,637	0.0948%
03시	6,994,432	6,653	0.0951%
04시	6,996,544	6,620	0.0946%
05시	7,004,779	8,510	0.1215%
06시	7,002,324	8,406	0.1200%
07시	6,999,998	8,416	0.1202%
08시	7,011,128	10,364	0.1478%
09시	7,010,842	10,373	0.1480%
10시	6,993,407	10,553	0.1509%
11시	7,006,371	13,978	0.1995%
12시	7,008,592	14,123	0.2015%
13시	7,009,876	13,461	0.1920%
14시	7,011,067	13,041	0.1860%


15시	7,004,710	13,295	0.1898%
16시	7,007,311	13,085	0.1867%
17시	7,000,558	10,570	0.1510%
18시	7,004,872	10,561	0.1508%
19시	6,996,701	10,238	0.1463%
20시	6,998,368	5,870	0.0839%
21시	6,990,693	5,731	0.0820%
22시	6,995,130	5,766	0.0824%
23시	6,991,437	5,776	0.0826%

3.4 날짜별 거래 추이

정상거래




패턴 자금 세탁거래




패턴 외 자금세탁 거래

- 11월 6일 이후로 없음



전체 비교




3.5. 통화·금액 일치 여부

- 모든 자금세탁 거래는 송금·수취 통화와 금액이 모두 일치한다.

통화 일치	금액 일치	행 수	자금세탁 거래 수	자금세탁 거래 비율
같음	같음	176,904,809	225,546	0.1275%
같음	다름	0	0	해당 없음
다름	같음	281	0	0.0000%
다름	다름	2,796,989	0	0.0000%

3.6 계좌별 거래 등장횟수




3.7 날짜별 거래 방식

- Reinvestment는 첫날과 매월 말일에 집중되며, 나머지 날짜에는 거의 발생하지 않는다.

Payment Format	ACH	Bitcoin	Cash	Cheque	Credit Card	Reinvestment	Wire	전체
date								
2022-08-01 00:00:00	345878	92912	268169	1036006	676316	1945609	101931	4466821
2022-08-02 00:00:00	233776	42904	206913	801558	573263	0	73170	1931584
2022-08-03 00:00:00	232570	42695	206913	800431	573267	0	73167	1929043
2022-08-04 00:00:00	232089	42468	206913	800337	573265	0	73174	1928246
2022-08-05 00:00:00	406936	63061	340677	1240166	855125	0	113178	3019143
...	...	...	...	...	...	...	...	...
2023-01-09 00:00:00	13	0	0	0	0	0	0	13
2023-01-10 00:00:00	8	0	0	0	0	0	0	8
2023-01-11 00:00:00	2	0	0	0	0	0	0	2
2023-01-12 00:00:00	6	0	0	0	0	0	0	6
전체	22126171	3904920	18412981	70586103	50856118	7410555	6405231	179702079

일자 추이



3.8 Payment Format별 자금세탁 일자 추이

전체 자금세탁거래 결제 방식 통계

결제 방식	전체 거래 수	자금세탁 거래 수	자금세탁 거래 비율
수표 (Cheque)	70,586,103	13,260	0.0188%
신용카드 (Credit Card)	50,856,118	7,846	0.0154%
자동결제망 이체 (ACH)	22,126,214	199,164	0.9001%
현금 (Cash)	18,412,981	3,663	0.0199%
재투자 (Reinvestment)	7,410,556	0	0.0000%
전신 송금 (Wire)	6,405,236	5	0.0001%
비트코인 (Bitcoin)	3,905,021	1,608	0.0412%

패턴 자금세탁

Payment Format	전체 거래 수
ACH	137,919
Bitcoin	13
Wire	4
전체	137,936

패턴 외 자금세탁


Payment Format	전체 거래 수
ACH	61,245

Bitcoin	1,595
Cash	3,663
Cheque	13,260
Credit Card	7,846
Wire	1
전체	87,610

3.9 통화별 자금세탁 거래 통계

송금 통화	수취 통화	전체 거래 수	자금세탁 거래 수
미국 달러 (US Dollar)	미국 달러 (US Dollar)	64,350,622	90,439
유로 (Euro)	유로 (Euro)	40,606,576	63,086
위안 (Yuan)	위안 (Yuan)	12,704,822	17,468
셰켈 (Shekel)	셰켈 (Shekel)	7,928,960	4,615
캐나다 달러 (Canadian Dollar)	캐나다 달러 (Canadian Dollar)	6,043,417	3,532
영국 파운드 (UK Pound)	영국 파운드 (UK Pound)	5,651,676	10,221
루블 (Ruble)	루블 (Ruble)	5,478,283	9,089
호주 달러 (Australian Dollar)	호주 달러 (Australian Dollar)	5,173,060	5,212
엔 (Yen)	엔 (Yen)	4,756,246	7,288
스위스 프랑 (Swiss Franc)	스위스 프랑 (Swiss Franc)	4,750,775	2,326
멕시코 페소 (Mexican Peso)	멕시코 페소 (Mexican Peso)	4,724,684	2,165
루피 (Rupee)	루피 (Rupee)	4,112,617	5,249
비트코인 (Bitcoin)	비트코인 (Bitcoin)	3,903,065	1,608
브라질 헤알 (Brazil Real)	브라질 헤알 (Brazil Real)	3,540,841	1,806
사우디 리얄 (Saudi Riyal)	사우디 리얄 (Saudi Riyal)	3,179,267	1,442

3.10 패턴별 지속 시간



패턴	시도 수	거래 수	지속시간 중앙값(일)	최대(일)	월 경계 초과 시도
BIPARTITE	2,109	12,174	10.43	16.95	524
CYCLE	2,086	12,340	29.18	35.02	1,640
FAN-IN	2,014	13,287	28.81	35.02	1,381
FAN-OUT	2,040	13,554	29.13	35.01	1,410
GATHER-SCATTER	2,054	26,361	55.76	70.45	1,612
RANDOM	2,001	9,618	20.52	35.00	1,055
SCATTER-GATHER	2,067	26,978	32.44	35.02	1,796
STACK	2,096	23,624	26.51	42.51	1,543

4. 모델 실험

4.1 전처리 과정

1. 원본 개 필드가 완전히 같은 HI-Large_Trans.csv의 거래의 중복건을 제거하여 179,702,079건을 사용
2. 은행 ID와 계좌번호로 그래프 노드를 만들고 거래 시각·방향·금액·통화 등을 엣지 정보로 구성한다.
3. 학습 이전인 2022년 8월 1~7일의 통화별 금액 분포로 금액 변환 기준을 고정
4. 노드 피쳐 19개, 엣지 피쳐 17개 사용

4.2 피쳐 추출 과정

1. 후보설계
 - 계좌 활동 거래 반복 시간 간격·금액·소유자 관계를 노드 및 엣지 피쳐로 정의
 - 41 처음에는 개의 후보 피쳐 선정
2. 순열 중요도
 - 학습된 모델에서 피쳐 값을 섞고 AP 하락을 측정
 - 모델이 해당 정보에 의존하는지 확인 단 상관된 피쳐가 있어 이 결과만으로 삭제를 결정하지 않음
3. 제거 후 재학습
 - 피쳐를 빼고 모델을 새로 학습해 검증 AP 비교
 - net_count_ratio를 뺀 40개의 가 AP 0.553941 0.578156 → 으로 올라 공통 입력으로 채택
4. 시간창 비교
 - 단기 거래 횟수 피쳐의 집계 범위를 30·60·180분으로 바꿔 재학습
 - 검증 가 각각 AP 0.547126·0.578156·0.559442여서 60분을 선택
5. IG 및 조합 제거
 - 기존 40개 모델의 Integrated Gradients(IG)로 집단별 설명 기여를 살피고, 8개 그룹의 256개 제거 조합을 검사
 - AP와 정밀도·재현율 등의 허용 손실 기준을 만족하는 35개 입력 구성을 선정
6. 신규 피쳐 추가 검증
 - 통화별 송금액을 평균·표준편차기준으로 변환한 amt_z_pay_ccy를 추가해 35 36 개와 개 모델을 재학습 비교
 - 3개 시드의 평균 검증 AP가 0.609885 0.621124 → 로 증가하여 개 36구성을 채택

노드 피쳐 19개

순서	피쳐	계산 정의
1	log_out_count	L(30일 문맥의 송금 거래 수). 자기 이체도 포함.
2	log_in_count	L(30일 문맥의 수취 거래 수). 자기 이체도 포함.
3	log_out_neighbors	L(서로 다른 수신 노드 수). 자기 이체가 있으면 자신도 상대 집합에 포함.
4	log_in_neighbors	L(서로 다른 송신 노드 수). 자기 이체가 있으면 자신도 상대 집합에 포함.
5	log_self_count	L(src=dst인 송금 거래 수). 다계좌 순환 횟수가 아님.
6	log_reciprocal_neighbors	L(A→B와 B→A가 모두 존재하는 상대 B 수). A 자신은 제외.

7	mean_paid_currency_z	30일 송금 거래의 paid_currency_z 평균. 송금이 없으면 0.
8	paid_outlier_fraction	30일 송금 중 $\text{abs}(\text{paid_currency_z}) \geq 3$ 인 비율. 송금이 없으면 0.
9	log_currency_count	$L(\text{송금 통화와 수취 통화의 합집합 크기})$. 거래 수가 아니라 통화 종류 수.
10	log_active_days	$L(\text{송금 또는 수취가 한 번 이상 발생한 날짜 수})$. 연속일 수가 아님.
11	type_Corporation	계좌 등록정보 entity_name에서 추출한 유형이 Corporation이면 1, 아니면 0. 이름 패턴 기반 원핫 인코딩.
12	type_Partnership	계좌 등록정보 entity_name에서 추출한 유형이 Partnership이면 1, 아니면 0. 이름 패턴 기반 원핫 인코딩.
13	type_Sole Proprietorship	계좌 등록정보 entity_name에서 추출한 유형이 Sole Proprietorship이면 1, 아니면 0. 이름 패턴 기반 원핫 인코딩.
14	type_Individual	계좌 등록정보 entity_name에서 추출한 유형이 Individual이면 1, 아니면 0. 이름 패턴 기반 원핫 인코딩.
15	type_Country	계좌 등록정보 entity_name에서 추출한 유형이 Country이면 1, 아니면 0. 이름 패턴 기반 원핫 인코딩.
16	type_Direct	계좌 등록정보 entity_name에서 추출한 유형이 Direct이면 1, 아니면 0. 이름 패턴 기반 원핫 인코딩.
17	log_entity_observed_accounts	$L(\text{같은 entity_id에 속하며 30일 문맥에서 활동한 계좌 수})$. 전체 등록 계좌 수가 아님. ID 미상은 0.
18	log_entity_out_diversity	$L(\text{해당 엔티티가 송금한 서로 다른 상대 엔티티 수})$. 양쪽 ID가 알려진 거래만 집계하며 같은 엔티티도 포함 가능.
19	log_entity_in_diversity	$L(\text{해당 엔티티가 수취한 서로 다른 상대 엔티티 수})$. 양쪽 ID가 알려진 거래만 집계하며 같은 엔티티도 포함 가능.

거래 엠티 피쳐 17개

순서	피쳐	계산 정의
1	pair_prior_count	$L(\text{현재 } t \text{보다 최소 1분 앞선 } A \rightarrow B \text{의 전체 누적 거래 수})$. 30일로 제한하지 않음.
2	pair_gap_minutes	$A \rightarrow B$ 의 마지막 이전 거래와 t 의 간격 Δ 분을 $G(\Delta)$ 로 변환. 같은 분 제외, 이전 거래가 없으면 0.
3	pair_count_1h	$L([t-60\text{분}, t-1\text{분}] \text{ 구간의 } A \rightarrow B \text{ 거래 수})$. 양 끝 포함.
4	sender_gap_minutes	A 의 마지막 이전 송금과 t 의 간격을 $G(\Delta)$ 로 변환. 상대 계좌 무관, 이력 없으면 0.
5	sender_count_1h	$L([t-60\text{분}, t-1\text{분}] \text{ 구간에서 } A \text{가 보낸 거래 수})$. 상대 계좌

		무관.
6	receiver_gap_minutes	B의 마지막 이전 수취와 t의 간격을 $G(\Delta)$ 로 변환. 송신 계좌 무관, 이력 없으면 0.
7	receiver_count_1h	$L([t-60\text{분}, t-1\text{분}] \text{ 구간에서 B가 받은 거래 수})$. 송신 계좌 무관.
8	paid_currency_z	현재 송금액의 통화별 강건 상대 점수 z. 중앙값-IQR 기준이며 표준편차 z-score가 아님.
9	pair_history_count	$L(\text{당일 } 00:00 \text{ 이전 } A \rightarrow B \text{ 누적 거래 수})$. 당일 발생분은 제외하며 30일 제한 없음.
10	reverse_history_count	$L(\text{당일 } 00:00 \text{ 이전 } B \rightarrow A \text{ 누적 거래 수})$. 자기 이체에서는 정방향과 같은 관계.
11	pair_age_at_day_start	당일 00:00과 마지막 이전 $A \rightarrow B$ 거래 사이 경과 분에 $G(\Delta)$ 적용. 이전 거래 없으면 0. 최초 거래 이후 나이가 아님.
12	same_entity	송신 entity_id가 알려져 있고 수신 entity_id와 같으면 1, 아니면 0.
13	same_known_country	은행명에서 추출한 두 국가가 모두 알려져 있고 같으면 1. 국가 미상도 0이므로 단독으로 국경 간 거래를 뜻하지 않음.
14	both_countries_known	송신.수신 은행명의 국가 추출값이 모두 UNKNOWN이 아니면 1.
15	same_currency	현재 거래의 payment_currency=receiving_currency이면 1, 아니면 0.
16	is_self_transfer	동일 은행.계좌로 정의한 송신 노드와 수신 노드가 같으면 1.
17	amt_z_pay_ccy	payment_currency별 보정 기간 송금액의 $\ln(1+\text{paid})$ 평균 μ_c 와 모표준편차 σ_c 로 계산한 $\text{clip}((\ln(1+\text{paid})-\mu_c)/(\sigma_c+1e-6), -10, 10)$. 평균 또는 표준편차가 유한하지 않으면 0. 기존 paid_currency_z와 함께 입력.

4.3 데이터 샘플링

IBM AML HI-Large 데이터는 정상 거래가 약 99.87%, 자금세탁 거래가 약 0.13%로, 클래스 불균형이 매우 크다. 대량의 정상 거래는 학습 비용을 증가시키며, 모델이 정상 거래에 편향될 가능성도 있다.

이에 이진분류와 유형분류의 각 실험에서 정상 거래를 줄이는 샘플링과 클래스 가중치를 적용하였다. 두 실험은 모델과 학습 대상이 다르므로 샘플링 방식 및 평가 결과를 구분하여 정리하였다.

4.3.1 이진분류의 정상 거래 샘플링

이진분류에서는 자금세탁 거래를 모두 유지하고, 정상 거래의 학습 대상 선정 방식을 다음과 같이 비교하였다. 패턴 정보가 없는 자금세탁 거래도 이진 라벨이 양성이면 유지한다.

방식	적용 방법
원본 사용	정상·자금세탁 거래 전체를 학습 대상으로 사용
랜덤 언더샘플링	일별 정상 거래에서 약 1%를 비복원 무작위 추출
군집 기반 언더샘플링	정상 거래를 군집화한 뒤 군집별로 표본 수를 배분하고 내부에서 비복원 무작위 추출(17개 거래 피쳐로 군집화)

군집 기반 방식은 학습 날짜별 정상 거래에서 최대 4,096건을 참조 표본으로 추출하고, 이 표본으로 표준화와 MiniBatch K-means를 적합한다. 기본 군집 수는 32개이며, 검증·시험 거래는 군집 적합에 사용하지 않는다.

일별 정상 거래의 약 1%를 추출 목표로 설정하되, 해당 날짜에 존재하는 군집마다 최소 1건을 남긴다. 나머지 표본 수는 군집 크기에 비례하는 비중 75%와 군집에 균등하게 배분하는 비중 25%를 혼합하여 배정한다.

이는 큰 군집의 비중을 반영하면서 작은 군집의 거래도 남기기 위한 방식이다. 군집별 최소 건수와 반올림이 적용되므로 최종 추출 비율이 항상 정확히 1%가 되는 것은 아니다.

이진분류의 표본 보정과 그래프 유지

정상 거래를 줄이면 각 거래가 학습에서 대표하는 원본 거래 수가 달라진다. 이를 보정하기 위해 추출 확률의 역수인 IPW(Inverse Probability Weighting)를 적용한다.

예를 들어 정상 거래 10,000건이 있는 군집에서 100건을 추출했다면, 선택된 거래 한 건에 100의 표본 가중치를 부여한다. 모두 유지한 양성 거래의 표본 가중치는 1이다.

이와 별도로 양성 거래의 학습 오류를 더 크게 반영하는 클래스 가중치 300을 적용한다. 두 가중치의 목적은 다음과 같이 다르다.

- IPW: 정상 거래를 적게 추출한 영향을 보정
- 양성 클래스 가중치: 자금세탁 거래의 오류를 학습에서 더 크게 반영

따라서 이진분류의 언더샘플링은 단순히 클래스 비율을 맞추는 작업보다는, 정상 거래의 분포를 고려하면서 학습 대상 수를 줄이는 방식이다.

또한 샘플링으로 선택하는 것은 정답과 손실을 계산할 대상 거래이다. 선택되지 않은 거래를 모두 그래프에서 삭제하지 않고, 별도로 구성한 일별 그래프에서 주변 거래 관계를 참조한다. 다만 모델이 보는 이웃에는 별도의 최근 거래 수·2홉 제한이 적용된다.

4.3.2 유형분류의 정상 거래 샘플링

유형분류에서는 정상과 자금세탁 패턴 8종을 구분하는 LightGBM 모델을 사용하였다. 패턴 양성 거래는 모두 유지하고, 정상 거래 선정 방식으로 k-means-CLARA k-medoids-CSSMC를 비교하였다.

방식	적용 방법
k-means	군집 중심에 가까운 실제 거래부터 선택
CLARA k-medoids	실제 거래로 구성된 대표점에 가까운 거래부터 선택
CSSMC	군집별 시간순 일정 간격으로 후보 표본 20개를 만들고, 원본과의 피쳐별 분포 차이가 가장 작은 후보 선택

정상 거래 수는 패턴 양성 1건당 10·30·100·300건으로 변경하였다. 각 조건에 가중치 없음과 양성 가중

치 300을 적용하고, 전체 데이터 대조군을 포함하여 총 25개 조건을 비교

이진분류와 달리 해당 유형분류 실험은 행을 무작위로 추출하지 않았으며, 군집별 표본에 IPW를 적용하는 비교도 수행하지 않았다. 패턴 정보가 없는 양성은 이번 유형분류의 학습·주요 평가에서 제외하고 별도로 분석하였다.

4.4 샘플링 결과 해석

샘플링의 효과는 분류 성능, 원본 분포 보존 정도, 학습 시간 및 메모리 사용량을 함께 고려하여 판단한다. 이진분류와 유형분류는 예측 대상과 평가 조건이 다르므로 결과를 구분하여 제시한다.

4.4.1 이진 분류 샘플링 결과

학습 구간의 정상 거래를 대상으로, 거래 피쳐 18개와 송신·수신 계좌 피쳐 각각 22개, 총 62개 피쳐 분포(송신 계좌 22개 + 수신 계좌 22개 + 거래 18개)의 평균 KL을 계산했다.

샘플링 방식	IPW 보정 전 평균 KL ↓	IPW 보정 후 평균 KL ↓
랜덤 언더샘플링	0.000004239	0.000004239
군집 기반 언더샘플링	0.001103961	0.000004298

4.4.2 유형 분류 샘플링 결과

유형분류는 정상 거래의 54개 입력 피쳐(송신 계좌 19개 + 수신 계좌 19개 + 거래 16개) 분포를 비교했습니다. 아래 평균 KL은 추출 비율 10:30:100:300 조건을 종합한 값이다.

샘플링 방식	평균 KL ↓	날짜별 보존율의 최대·최소 비율 ¹
k-means 기반	0.04123	12.08배
CLARA k-medoids 기반	0.01129	2.10배
CSSMC 기반	0.000002765	1.05배

4.5. 이진 분류

실험 목적과 구성

TGNN, GAT, GATv2, GINE, Edge GraphSAGE, Edge-weighted GCN의 6종에 대해 원본 학습, 랜덤 언더샘플링, 군집 기반 언더샘플링을 비교하였다.

각 조건에 3개 시드(원본, 랜덤, 군집)를 적용하여 총 54개 실험을 수행하였다. 프로젝트에서 TGNN으로 부르는 모델은 TransformerConv 기반 모델이며, 별도의 이벤트 메모리를 갖는 TGN 구조와는 구분한다.

분할

train : 2022-08-08~09-27

test : 09-28~10-14

validation : 10-15~10-31

데이터 입력

- 노드 피처 19개 → 입출금 횟수, 거래 상대 수, 활동일 수, 금액 특성, 소유 주체 유형과 거래 관계 등
- 거래 피처 17개 → 동일 계좌쌍의 과거 거래 횟수, 직전 거래와의 시간 간격, 최근 1시간 거래 빈도, 통화별 금액 점수, 동일 소유 주체 여부 등

주요 결과

모델·학습 방식	AP	정밀도	재현율	F1
TGNN·원본	0.6028	0.7801	0.5450	0.6414
TGNN·랜덤 언더샘플링	0.6159	0.7839	0.5437	0.6420
TGNN·군집 언더샘플링	0.6211	0.8071	0.5427	0.6489
GAT·원본	0.6134	0.8191	0.5537	0.6607
Edge-weighted GCN·원본	0.6141	0.8256	0.5488	0.6592

※ 전체 비교 중 주요 조건을 제시하였으며, 수치는 3개 학습 시드의 평균이다.

결과 해석

검증 AP 기준으로 TGNN·군집 언더샘플링이 **0.6211 ± 0.0059**로 가장 높은 결과를 보였다. ±는 학습 시드 간 표준편차이다.

같은 TGNN의 원본 사용 조건과 비교하면 AP는 0.6028에서 0.6211로, 정밀도는 0.7801에서 0.8071로 개선되었다. 반면 재현율은 0.5450에서 0.5427로 비슷한 수준을 유지하였다. 따라서 군집 언더샘플링이 모든 지표를 함께 개선했다고 해석하지 않는다.

AP가 가장 높은 조건과 F1이 가장 높은 조건도 달랐다. TGNN·군집 언더샘플링은 위험 거래의 순위 평가에서, GAT·원본은 선택된 임계값에서의 정밀도·재현율 균형에서 상대적으로 높은 결과를 보였다.

현재 TGNN·군집 언더샘플링의 재현율은 약 54.3%로, 더 많은 자금세탁 거래를 탐지하기 위한 개선이 필요하다.

4.6 유형 분류

실험 목적과 구성

유형분류는 거래별 위험 여부와 함께 의심되는 거래 유형을 제공하기 위한 기능이다. 정상 거래와 자금 세탁 패턴 8종을 구분하는 9클래스 분류로 구성하였다.

LightGBM을 기준 모델로 사용하여 정상 거래의 샘플링 방식·비율·클래스 가중치를 비교하였다. 샘플링 3 방식, 정상 거래 비율 4종, 가중치 2종의 24개 조건과 전체 데이터 대조군 1개를 포함하여 총 25개 조건을 실험하였다. 별도로 TGNN의 출력을 9개 클래스로 구성한 유형분류 모델을 비교하였다.

분할

- 이진 분류와 동일

결과

모델·학습 조건	9클래스 Macro-AP	패턴 8종 Macro-AP	Macro-F1	패턴 거래의 유형 정답률
LightGBM·CSSMC r300 w300	0.2812	0.1913	0.3154	35.0%
LightGBM·전체 데이터·양성 가중치 300	0.2748	0.1841	0.3065	34.4%
TGNN·전체 데이터·양성 가중치 300	0.1684	0.0645	0.1457	10.6%

※ r300은 정상 : 패턴 양성을 300 : 1로 구성한 조건이며, w300은 패턴 양성에 학습 가중치 300을 적용한 조건이다. 수치는 단일 학습 시드의 시험 결과이다.

결과 해석

LightGBM·CSSMC r300 w300 조합은 시험 Macro-AP **0.2812**, Macro-F1 **0.3154**로 비교한 모델 중 가장 높은 결과를 보였다. 전체 데이터 대조군보다 학습 거래 수를 줄이면서 비슷하거나 조금 높은 성능을 확인하였다.

다만 패턴 거래의 유형 정답률은 약 **35.0%**로, 자금세탁 거래가 어느 유형에 해당하는지 구분하는 성능에는 개선이 필요하다. 유형별 재현율도 STACK은 0.614, SCATTER-GATHER는 0.473인 반면 RANDOM은 0.050으로 차이가 컸다.

5. 현재 Alert 생성 알고리즘**5.1 목적과 입력**

이진 분류 모델이 산출한 거래별 위험 점수를 이용해 **씨앗 거래**를 선정하고, 계좌 연결 관계와 거래 시각을 바탕으로 관련 거래를 탐색하여 조사용 서브그래프를 생성한다.

주요 입력은 통합 거래 ID, 송수신 계좌, 거래 시각, 거래 속성, 이진분류 점수, 분석별 임계값 및 분석 기준 시점이다. 정답 라벨과 패턴 시도 ID는 운영 입력에서 제외하고 평가에만 사용한다.

유형분류 결과는 거래의 의심 유형을 설명하는 데 사용한다.

5.2 씨앗 거래 선정

이진분류 위험 점수가 해당 분석 실행의 임계값 이상인 거래를 씨앗으로 선정한다. 현재는 임계값 방식이며, 조사 가능량에 맞춰 상위 N건을 선택하는 방식은 적용하지 않는다. 분석 기준 시점까지 수신·통합된 거래와 검증된 모델 결과를 기준으로 처리한다.

5.3 주변 거래 탐색

씨앗 거래가 $A \rightarrow B$ 인 경우 다음 관계를 확인한다.

관계	예시	처리
상류	씨앗보다 이전에 발생한 $X \rightarrow A$	자금 유입 방향으로 추가 탐색
하류	씨앗보다 이후에 발생한 $B \rightarrow Y$	자금 유출 방향으로 추가 탐색
송금 계좌 공유	$A \rightarrow C$	병렬 맥락으로 포함 가능
수취 계좌 공유	$D \rightarrow B$	병렬 맥락으로 포함 가능

병렬 맥락 거래는 포함할 수 있지만, 병렬 관계만을 이유로 계속 확장하지 않는다. 동일 시각의 거래는 선후관계를 확정할 수 없어 상류·하류 연결에서 제외한다.

정상으로 예측된 거래나 미분석 거래도 자금 흐름을 설명하기 위한 연결·참고 거래로 포함될 수 있다. 포함 사실 자체가 해당 거래의 위험 판정을 의미하지는 않는다.

5.4 탐색 범위와 제한

항목	현재 정책
시간 범위	탐색 중인 거래의 KST 거래일을 기준으로 전후 2일 범위
데이터 가용성	분석 기준 시점까지 수신·통합된 거래
탐색 깊이	씨앗 거래에서 최대 2단계
후보 크기	씨앗·연결·참고 거래를 합하여 최대 100건
고활동 계좌 제한	조회 범위의 입출금 고유 거래가 100건을 초과하면 해당 계좌의 탐색 가지 생략
탐색 방식	너비 우선 탐색
동일 단계의 처리 순서	최초 씨앗과의 시간 차이 → 거래 시각 → 거래 ID

시간 범위는 탐색 중인 거래를 기준으로 이동하므로, Alert 전체 기간이 고정된 5일로 제한되는 것은 아니다. 금액이나 위험 점수가 높다는 이유로 주변 거래를 우선 편입하지 않는다.

5.5 후보 병합

후보 Alert가 실제 거래를 공유하면 병합 가능성을 검토한다. 이때 한 후보의 씨앗 거래가 다른 후보에 포함되고, 병합 후 고유 거래 수가 100건 이하인 경우에 병합한다.

동일 계좌를 사용하거나 예측 유형이 같다는 이유만으로 직접 병합하지 않는다. 참고 거래만 공유하고 씨앗의 교차 포함이 없다면 병합하지 않는다.

병합된 후보가 다른 후보와 다시 조건을 충족하면 연쇄 병합이 가능하다.

5.6 저장 및 갱신

거래별 역할과 포함 이유를 함께 저장한다.

- SEED: 위험 점수가 임계값 이상인 씨앗 거래
- CONNECTION: 상류·하류의 자금 흐름을 연결하는 거래
- CONTEXT: 동일 송금·수취 계좌 등 참고 관계의 거래

5.7 현재 검증 결과와 한계

오프라인 사례 분석에서 씨앗 간 병합, 연쇄 병합, 병렬 맥락 포함 및 고활동 계좌 제한에 따른 탐색 생략을 확인하였다.

한 사례에서는 조회 범위에 활동 거래 2,540건이 있는 허브 계좌가 포함되었으나, 제한 적용 후 후보 Alert에는 6건만 포함되었다. 이는 탐색 범위가 통제되는 동시에 일부 흐름이 누락될 수 있음을 보여준다.

현재 남은 과제는 다음과 같다.

- 계좌와 시간 연결만으로 동일한 의심 활동인지 설명할 수 있는지 검증
- 연쇄 병합에 따른 과도한 범위 확대 점검
- 고활동 계좌 제한으로 누락되는 상류·하류 관계 측정
- 참고 거래가 100건 한도를 차지하여 핵심 거래 보강을 제한하는 문제 점검

- 실제 모델 결과를 사용한 연관 거래 회수, 시나리오 분절·혼합, 중복 검토량 평가

현재 사례는 데이터 범위와 씨앗 조건이 서로 달라 최종 Alert 품질 수치로 사용할 수 없다. 그래프에 표시된 거래 금액을 단순 합산한 값도 고유한 자금세탁 원금으로 해석하지 않는다.

6. 현재구현 상태

현재 MVP는 사전에 변환한 시연용 데이터를 이용하여 조사자의 핵심 업무 흐름을 확인까지 최소한의 기능을 제공하는 것이다. (룰 엔진 제외)

6.1 현재 진행상황

로그인기능

- 세션 로그인 활용
- API 요청 시마다 인증 정보 확인(단, 캐싱된 정보는 현재 인증없이 바로 보여진다.)

금융기관별 거래 CSV 수신 및 S3 저장 기능

- 현재 시연에서는 시연용 데이터를 활용해서 저장하고 있다.

파일 검증·가명화·통합 → 모델 입력 파일 생성 기능

- 현재 데이터셋에서 은행별로 분리한 데이터를 활용하여 구현하였다.

결과 파일 검증 및 DB 저장

서브그래프·Alert 생성

- 5번(현재 Alert 생성 알고리즘)을 바탕으로 구현하였고 추가 보완이 필요하다.

화면 API

- 대시보드 : 기관 전체 현황 및 개인 담당 업무 조회
- 거래 조회 기능
- Alert: 조회(목록, 상세), 분석 종결 기능
- Episode 생성, 조회(목록, 상세), 삭제, 분석 종결 기능

이진·유형분류 추론

- 현재 외부의 GPU를 빌려서 사용하고 있는데 학원 IP를 제외하고는 인바운드 트래픽이 차단되어 있는 상태라 서비스와 연동은 되어 있지 않다.
- 허용 요청 상태(허용 거부시 네이버 클라우드 GPU 사용 예정)
- 현재까지 도출한 피처를 바탕으로 여러 샘플링 방법을 실험중이며 기본적인 GNN 모델로 테스트만 진행한 상태

7. 앞으로 할 일

7.1 이진·유형분류 추론

현재 모델의 학습 안정성과 거래 관계 표현을 개선하기 위해 다음 작업을 진행할 예정이다.

그래프 구조 표현 강화

송금·수취 방향을 구분하는 Reverse MP, 기준 계좌를 표시하는 Ego ID, 연결을 구분하는 Port numbering을 단계적으로 적용한다. 각 기법이 FAN-IN·FAN-OUT·CYCLE 등 유형별 탐지 성능에 미치는 영향을 확인한다.

거래 표현과 탐색 깊이 확장

GNN 층마다 거래 표현을 갱신하는 Edge update와 3홉·3층 구성을 비교한다. 더 넓은 거래 관계를 반영했을 때의 성능 변화와 메모리·처리시간 증가를 함께 측정한다.

GNN과 LightGBM 결합 비교

GNN으로 생성한 임베딩을 LightGBM에 입력하는 방식을 실험한다.

각 개선안은 하나씩 적용하여 기존 모델과 비교한다. 이진분류는 AP·정밀도·재현율·F1을, 유형분류는 Macro-AP·Macro-F1과 유형별 재현율을 중심으로 평가한다.

7.2 Alert 생성 알고리즘 검증 및 개선

실제 추론 결과를 바탕으로 Alert 생성 알고리즘 실행했을 때 결과를 확인하고 검증하고 개선하는 과정이 필요하다.

7.3 Alert 간의 관계를 보여 줄 수 있는 추가 정보 제공

현재 Alert 상세 페이지에서 Alert에 대한 정보를 제공하고 있지만 Episode를 생성하기 위해서는 서로 연관 있는 Alert를 사용자가 알 수 있어야 한다.

- Alert 상세 페이지 Alert와 연관 있는 Alert 후보와 연관 근거가 되는 정보를 보여주기
- Alert 목록 페이지에서 여러 Alert를 선택했을 때 선택한 Alert간 관계 정보를 보여주기

7.4 Episode에 속한 Alert간의 관계를 확인 할 수 있는 정보 제공

현재 Episode를 생성했을 때, 그 Episode에 속한 Alert들이 왜 서로 연관이 있다고 사용자가 판단을 했는지에 대한 정보가 보여져야 하는데 현재 화면에서는 Alert간의 관계를 확인하기 어렵다.

7.5 GPU 서버와 백엔드 서버 연결

- 현재 GPU 서버 인바운드 허용 요청 결과에 따라 작업을 수행한다.(GPU vs 네이버 클라우드)

7.6 룰 엔진 기반 자금세탁 탐지기능 구현

방식에 따라 두가지로 나눌 수 있고 전자를 필수적으로 구현하고자 한다.

1. 룰 템플릿의 파라미터를 조정하는 방식

- IF/THEN → 백테스트 → 승인 → Shadow → 운영

2. 자연어를 룰로 변환하는 방식

- LLM 구조화 초안 생성 → 검증 가능한 Rule DSL → 구문·의미·성능 검증 → 백테스트 → 승인 → Shadow → 운영

7.7 렌더링 성능 최적화

현재 페이지 접근시 매번 전체 데이터를 조회하고 있어 최초 로딩시간이 너무 길다.

8. 현재 고민 사항

8.1 현재 **이진분류모델 추론 결과**로 Alert를 생성하고 생성한 Alert에 있는 거래 내역의 각 유형분류모델 추론 결과를 높은것 들을 나열하는 방식으로 구상했었는데 생성한 Alert를 유형 분류모델에 넣어서 결과를 보여주는 것은 어떤지 고민중입니다.

8.2 사용자가 자금세탁을 모니터링 하기 위한 적절한 정보를 제공하고 있는지?